사회조사방법론
확률표집과 비확률표집

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

April 25, 2022

진행 순서

1. 표집의 기초 개념
2. 확률표집
3. 비확률표집

표집의 기초 개념

표집의 기초 개념

표집에는 몇 가지 기초 개념들이 복잡하게 얽혀있다.

- 표집(sampling)은 표본(sample)을 추출하는 과정인데, 우리는 표본의 성격을 통해 모집단(population)의 성격을 추론(inference)하고자 한다.
- 포본의 총체적인 특성이 모집단의 총체적인 특성에 근접할수록 대표성있는 (representative) 표본이라고 부른다.
- 종종 우리는 모집단과 완벽하게 일치하지 않는 연구모집단(study population)을 상정한다. 예를 들어 제주도를 제외한 전국에서 설문조사가 종종 수행된다. 미국에서는 하와이(Hawaii)와 알래스카(Alaska)를 제외한 전국에서 설문조사가 종종 수행된다.

표집의 기초 개념

- 표집이 이루어지는 단위를 요소(element) 또는 표집단위(sampling unit)라고 부르는데, 이는 실질적으로 관찰단위(unit of observation)와 같은 개념이다.
- "표집될 확률"을 미리 알 수 있으려면 결국 모든 요소들이 총망라된 표집틀(sampling frame)이 미리 준비되어야 한다.
- (연구 목적에 따라) 주민등록자, 납세자, 신용카드 소지자, 자동차 소유자, 복지 수혜자, 사업자등록자, 전문직 면허소지자 등 각종 명부(registry)를 표집틀로 사용할 수 있다.
- 표집틀에 문제가 있으면 아무리 대규모로 조사하더라도 의미가 없다. Babbie (2021: 291–292)에 소개된 Reader's Digest 사례는 무엇을 시사하나?

표집의 기초 개념

- 옛날에는 전화번호부(yellow pages)라는 것을 사용할 수 있었다. 이것은 전국민의 이름 또는 상호명과 함께 전화번호가 적혀있는 두꺼운 책이다.
- 전화번호부는 표집틀로서 굴곡의 역사를 가졌다. 오래 전에는 전화기를 살만큼 부유하지 못한 이들을 배제한다는 이유로 비판받았고, 오늘날에는 누가 유선(landline) 전화기를 쓰느냐는 이유로 비난받는다.
- 무작위 전화걸기(random-digit dialing; RDD)는 그 대안 중 하나이다. 다만 휴대폰에도 응답거부나 스팸차단 기능이 있어 설문조사가 가로막히기 쉽다.

표집의 기초 개념

- 어긋남(bias)이란 모집단과 성격과 표본의 성격이 "평균적으로" 얼마나 다른가에 관해 보여준다.
- 표본에서 얻은 추정량(estimator)이 $\hat{\theta}$이고, 진정 알고자 하는 참값이 θ이라면,

$$Bias = E(\hat{\theta} - \theta)$$

- 가령 모집단의 평균이 10인데 내가 가진 표본의 평균이 9라면 1만큼 하나의 "차이"를 찾은 셈이다.
- 무한히 계속 표본을 뽑아 "차이"을 모으다보면 어긋남의 표집분포(sampling distribution)를 생각할 수 있다. 이 표집분포의 평균이 바로 어긋남이다.
- 다시 말해, 우리가 무한히 계속 표본을 뽑고 각각의 표본평균을 모평균에서 뺀 값 $\hat{\theta} - \theta$을 구한다고 하자. 그것이 평균적으로 0일 때, 어긋남없음(unbiased)이라고 말할 수 있다.

확률표집

확률표집

확률표집일 때만 (추정이나 가설검정 등) 통계 이론을 사용할 수 있다.

- 어떤 요소가 "표본이 될 확률"을 (미리) 가지고, 그것이 0은 아닌 표집방식을 일컫어 확률표집(probability sampling)이라고 한다.
- 확률표집 개념은 그다지 직관적이지 않으므로 무엇이 확률표집이 아닌가로부터 생각을 출발하자.
- 당신의 친구를 대충 표본으로 삼으면 그 사람이 "표집될 확률"을 알 수 없으므로 확률표집이 아니다(Why?).
- 반면에 전인구를 포괄하는 표집틀에서 임의(random)로 뽑았다면 "표집될 확률"을 알 수 있다(Why?).

확률표집

왜 요소가 "표본이 될 확률"을 가져야 통계이론을 사용할 수 있을까?

- 우리는 모집단(population)에서 표본(sample)을 골라내고, 표본의 성질인 통계량(statistic)로부터 모집단의 성질인 모수(parameter)를 유추해 내고(make inference) 싶다.
- 이렇게 "표본으로부터 유추된 성질"이 (모집단과는 상관없이) 그저 표본만에서 우연히 나타났을 확률을 알고 싶기 때문에 확률이론을 필요로 한다.
- 당연히 요소가 "표본이 된 확률"에 대한 정보없이 이런 확률을 계산할 수 없다.
- 그러므로 우리는 표본에 대해 확률이론이 성립하려면 확률표집을 사용해야 한다는 결론에 도달한다.

확률표집

첫번째 확률표집으로 임의로 표본을 뽑는 방식이 있다.

- 단순임의표집(simple random sampling) 또는 단순무작위표집은 모든 모집단 구성원이 $1/N$로 동등한 추출 확률을 갖는 표집 방식이다.
- 먼저 전체 표집틀을 준비한다. 각각의 표집단위에 대해 고유번호를 부여한다.

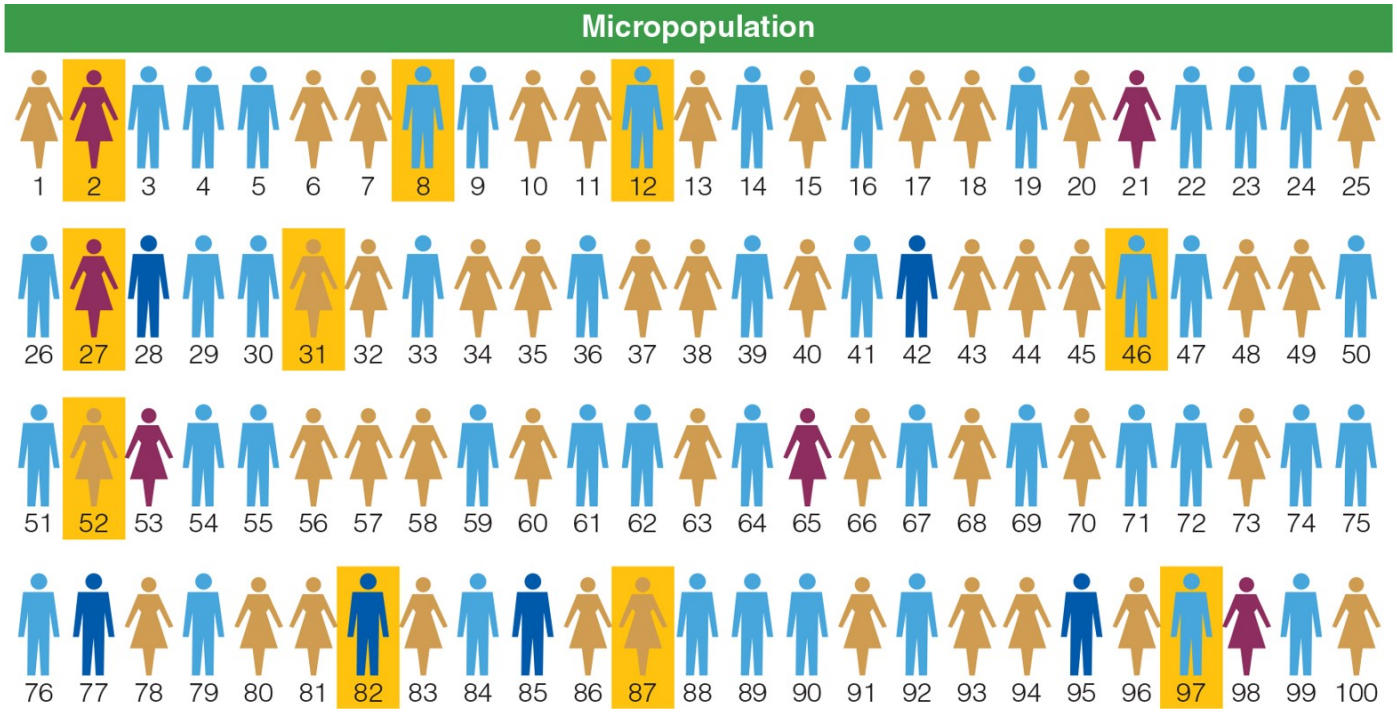

확률표집

- 다시 난수발생기(random number generator; RNG)를 통해 임의의 숫자(=난수)를 만들어내고 그 번호에 일치하는 요소를 추출한다.
- 이 방식을 따르면 모집단의 모든 구성원은 표본으로 추출될 가능성이 $1/N$이므로 (Why?), 정의상 확률표집이 된다.

Table of Random Numbers

51426	00609	13501
50202	20368	36181
68568	00811	38612
43803	59549	54997
99389	22930	38246
40012	09599	48287
46202	33334	78502
92106	13420	52252
55478	36951	81131
95888	44841	62382
63752	70740	30727
39706	31586	36108
70394	94351	22457
24328	66613	72883
19300	45923	02358

The Sample

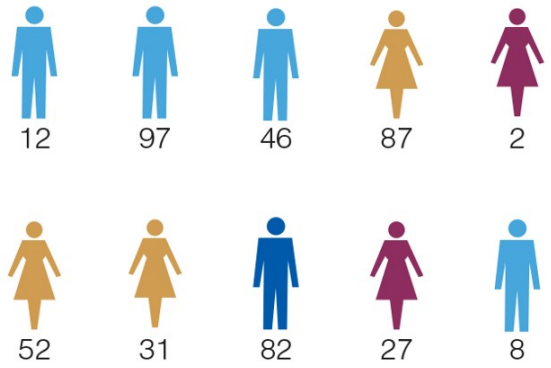

확률표집

- 단순임의표집은 이른바 균일확률추출법(equal probability of selection method; EPSEM)을 따른다. 이름 그대로 모집단의 각 구성원이 표본으로 추출될 가능성이 동일하기 때문이다.
- 단순임의표집은 가장 이상적인 표집 방식이지만 현실적으로 매우 어렵다.
- 첫째, 표집틀 구성은 종종 설문조사의 모든 단계에서 가장 비용을 소비하는 단계이다. 그런데 전체 모집단의 표집틀을 만들다보면 비용이 천문학적으로 깨진다.
- 둘째, 전체 모집단(e.g., 전국)에서 드문드문 흩어져 있는 사람들을 추적해 다니다보면 조사비용도 크게 소요된다.
- 결국 모집단이 국지적인 경우에나 활용될 수 있다.

확률표집

두번째 방법은 표집틀에서 일정 간격으로 건너뛰면서 표집하는 것이다.

- 계통표집(systematic sampling)은 미리 모집단 대비 표본 비율, 즉 표집비(sampling ratio)를 정해놓고, 그 비율을 달성할 수 있는 간격(interval)을 계산하는 것에서 출발한다.
- 가령 100명이 사는 마을 구성원을 모집단으로 하고 여기서 10명의 표본을 뽑고자 한다. 이 경우 표집비는 $100/10 = 10$ 이므로 간격은 10이다.
- 그 뒤, (간격 이내) 임의의 숫자를 뽑아 몇 번째부터(예를 들어 3) 출발할 것인가를 정하고 10명씩 건너뛰면서 표집한다.

확률표집

Random start
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25
26 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50
51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75
76 77 78 79 80 81 82 83 84 85 86 87 88 89 90 91 92 93 94 95 96 97 98 99 100

확률표집

- 생각보다 이곳저곳에서 사용된다! 내용분석(content analysis)에서도 전수조사하기 곤란한 경우 (짝수 페이지만 읽거나 매월 15일자 자료만 읽거나 하는 식으로) 이 방식을 사용할 수 있다.
- 가령 신문을 읽고 거기에서 집회시위에 관한 자료를 추출해낸다고 하자. 이때 매주 월요일 신문만 읽는 것도 하나의 방식이다.
- 그러나 어떤 이유로든 만일 짝수 페이지, 매월 15일자, 매주 월요일에 특정 내용이 치우친다면 이는 대표성 없는 표본을 생산한다.

확률표집

세번째로 먼저 요소를 동질적인 층으로 묶고 그 안에서 다시 표집할 수 있다.

- 층화표집(stratified sampling)은 먼저 최대한 동질적인 층들(strata)을 구성하는 것에서 출발한다.
- 층화(stratification) 방식이 문제가 되는데, 가장 단순하게는 교육수준, 수입, 연령대 등의 기준을 활용할 수 있다.
- 각각의 "층 내부에서(within stratum)" 다시 구성원을 표집하는데, 그 방식은 임의표집, 집락표집, 계통표집 중 어느 것이든 사용할 수 있다.

확률표집

- 가령 대학생의 정치적 이데올로기를 조사한다면, (1학년에서 4학년까지) 학년별로 층화하여 각 100명씩 임의표집할 수 있다.
- 만약 층 내부에서 임의표집한다면 이것은 임의층화표집(random stratified sampling)이 된다.
- 만약 1학년이 200명, 2학년이 300명, 3학년이 200명, 4학년이 300명으로 총합 1,000명이라면, 1학년을 20%, 2학년을 30%, 3학년을 20%, 4학년을 30%으로 임의표집할 수 있다.
- 이렇게 모집단 크기에 표본 크기를 비례시키는 방식을 비례층화표집(proportionate stratified sampling)이라고 부른다.
- 비례배분(proportional allocation) 방식은 정비례 말고도 다양하며 특히 소수자(minority)를 표집하기 위해서라면 신중하게 그 방식을 고려해야 한다.

확률표집

네번째는 군집을 뽑고 그 안에서만 표집틀을 만들어 비용을 절감하는 방식이다.

- 집락표집(cluster sampling)은 (단순임의표집과는 달리) 전체 모집단의 표집틀을 만들지 않고, (기존의) 집락(clusters) 또는 구역(blocks) 중 표집된 구역에 한해서만 목록(표집틀)을 만드는 방식이다.
- 일단 표집된 구역에서 표집틀을 구성한 다음에는 다시 그 안에서 내부 구성단위를 표집한다.
- 도시같은 이미 명확하게 주어진 집락이 있는 경우에 특히 유용하다.

확률표집

- 많은 경우 종종 다단계 집락표집(multi-stage cluster sampling)이 사용되곤 한다.
  (1) 기성의 나뉘어진 구역들을 먼저 표집한다.
  (2) 각각의 구역 안에서 다시 가구(households)의 목록(표집틀)을 만든다.
  (3) 이 표집틀에서 가구들을 (임의, 계통, 층화) 표집한다.
  (4) 가구 안에서 사람들의 목록(표집틀)을 다시 만든다.
  (5) 이 표집틀에서 사람들을 (임의, 계통, 층화) 표집한다.
- 만약 1,000개의 도시 구획에서 100개 구획을 표집하고, 다시 100개의 구획에서 10개의 가구씩 표집한다면 (최종적으로) 각 가구가 "표본이 될 확률"은 다음과 같다.

$$\frac{100}{1,000} \cdot \frac{10}{100} = \frac{1}{100}$$

확률표집

- 동그라미(e.g., 흑인)의 비율을 추정하고자 하는 상황에서 모집단 비율은 0.5 임을 안다.
- 우리가 여섯 개의 도시 구획 중에서 두 개를 뽑고 표본비율을 계산해보면 평균적으로 0.5이므로 왜곡없음(unbiased)을 알 수 있다(Why?).
- 임의표집과는 달리 전국 각지로 조사원을 보낼 필요가 없어 비용을 줄일 수 있다 (Why?).
- 그러나 아쉽게도 추정 비율의 변동성, 즉 표준오차(standard error)가 커진다(Why?)

확률표집

Frame Population

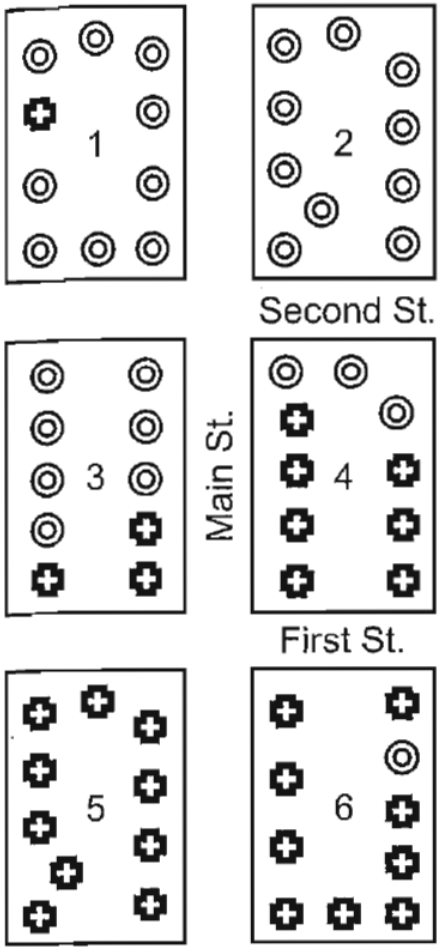

Samples of Two Distinct Blocks
(Proportion "◎" Households in Realization)

Block Numbers	Proportion "◎"
1,2	19/20 = .95 *
2,3	17/20 = .85 *
1,3	16/20 = .80 *
2,4	13/20 = .65
1,4	12/20 = .60
2,6	11/20 = .55
1,6	10/20 = .50
2,5	10/20 = .50
3,4	10/20 = .50
1,5	9/20 = .45
3,6	8/20 = .40
3,5	7/20 = .35
4,6	4/20 = .20 *
4,5	3/20 = .15 *
5,6	1/20 = .05 *

확률표집

- 다단계 집락표집에서는 종종 크기비례확률(probability proportional to size; PPS)을 사용한다.
- 현실에서는 집락표집에 사용되는 구역(blocks)의 크기가 제각각인 경우가 많다. 이런 경우 첫번째 단계에서 집락을 표집할 때, (아직 고려하지 않은) 두번째 단계의 이질성(heterogeneity)을 놓치기 쉽다.
- 그러므로 두번째 단계의 이질성을 미리 고려하여 첫번째 단계의 구역 표집에서 "표본이 될 확률"을 일부러 다르게 설정할 수 있다.
- 가령 첫번째 단계는 지역(areas)이고 두번째 단계는 가구(households)라면, 지역을 표집할 때 가구 수가 많은 지역에 "표본이 될 확률"을 일부러 높게 부여할 수 있다 (Babbie 2021: 341).

확률표집

- 층화표집과 집락표집은 분명히 좀 비슷한 구석이 있지만 과정은 명백히 다르다.

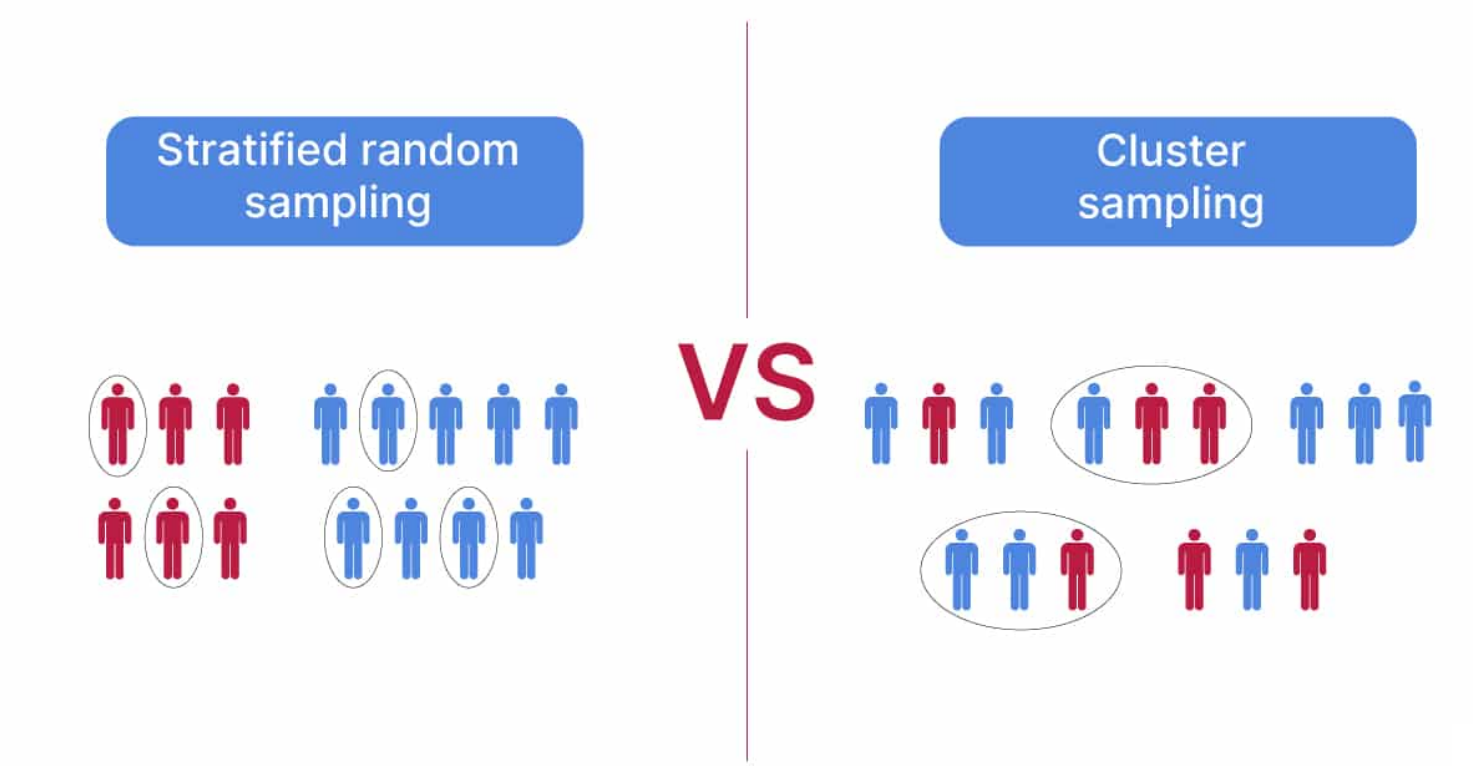

확률표집

확률표집을 선택한다면 무얼 골라도 똑같은 걸까?

- 안타깝지만 그렇지 않다. 확률표집 방식에 따라 조사 비용이나 편의성 뿐 아니라 표집오차(sampling error)도 달라지기 때문이다.
- 표집오차란 모집단 전체를 조사했다면 발생하지 않았겠지만, 표본을 조사했기 때문에 필연적으로 발생하는 오류이다. 동일한 모집단에서 표본을 새로 뽑을때마다 표집오차가 매번 달라진다.

확률표집

- 단순임의표본은 (하나의 표집오차에만 영향받기 때문에) 다른 확률표집 방법보다 표집오차가 더 작다. 그러나 층화표본이나 집락표본은 두 개의 표집오차에 영향받는다.
- 층이나 집락을 먼저 뽑는데서 발생하는 표집오차가 있고, 다시 그 안에서 새로 뽑는데서 발생하는 표집오차가 있기 때문이다.
- 결국 우리는 임의표집의 작은 표집오차를 비용 문제로 포기하고, 그 대신 계통표집, 층화표집, 집락표집을 선택하여 좀 더 큰 표집오차를 저비용으로 수용하는 셈이다.
- 표집방식의 설계효과(design effect)를 통해 다른 표집 방법을 임의표집에 비교하여 얼마나 더 큰 표집오차를 가지게 되는지 알 수 있다.

비확률표집

비확률표집

첫째로 편의성을 가장 우선시하고 되는대로 뽑는 비확률표집 방법이 있다.

- 이것이 이른바 편의표집(convenient sampling)으로, 과학적으로 엄밀하지 않은 연구에서 생각보다 자주 사용된다.
- 이것의 과학적 엄밀성은 별점/혈액형 성격판단 수준과 유사하다. (특히 정치적 목적을 담은) 사이비 사회과학 조사나 (사실상 광고 역할을 수행하는) 사이비 마케팅 조사가 이 방식으로 대량생산된다.
- (1) 구글 폼(Google Forms)을 사용하여 친구나 내부 구성원에게 설문조사하는 방법, (2) 길가의 사람들을 적당히 붙잡아 설문조사하는 방법, (3) 인터넷 웹사이트에서 "설문조사 좀 하실래요?"로 유도하는 방법(이른바 opt-in) 등은 모두 편의표집에 불과하며 그 발견은 결코 표본을 넘어 일반화(generalization)될 수 없다.

비확률표집

- 종종 임의표집(random sampling)과 편의표집을 혼동하는데 양자는 완전히 다르다. 내 맘대로(임의대로) 표본추출하는 것은 편의표집이지 임의표집이 아니다.
- 임의표집은 가장 이상적인(그러나 현실적으로는 거의 불가능한) 확률표집 방법인 반면, 편의표집은 가장 엉망인(그러므로 현실에서 자주 사용되는) 비확률표집이다.
- 사전조사(pilot test) 목적이라면 비확률표집이라도 사실 큰 문제는 없다.

비확률표집

두번째로 전문가의 판단에 맡기는 접근방법이 있다.

- 이른바 목적표집(purposive sampling) 또는 판단표집(judgment sampling)은 연구자 또는 전문가의 판단 아래에 가장 대표성 있다고 생각되는 대상을 표집하는 방식이다.
- 모집단에 대해 잘 안다고 여겨지는 전문가에게 표집을 위임할 수도 있다. 예를 들어 담임교사에게 학급을 대표하는 학생 10명 뽑아달라고 부탁하는 것이다.
- 대안이 없을 때는 이것이 최선일 수도 있다. 하지만 전문가의 판단이 얼마나 왜곡되기 쉬운지 알 길이 없으므로 본질상 비확률표집이다.

비확률표집

세번째로 아는 사람을 계속해서 소개받는 접근방법이 있다.

- 대중적으로 잘 알려진 눈덩이표집(snowball sampling)으로, 일단 특정 대상을 찾아가 조사하고 아는 사람을 소개받아, 다시 그 사람을 조사하는 방식으로 확장해 나가는 방식이다.
- 이른바 소셜 네트워크(social network)을 따라 이어져 나가므로, 노숙자, 마약상용자 등 숨겨진 모집단(hidden population)의 구조를 파헤치기 위해 매우 중요한 방법으로 여겨진다.
- 비교적 근래에 Douglas D. Heckathorn이 주창한 응답자유도 표집 (respondent-driven sampling)이 이 접근방법을 개선한 것으로 각광받고 있고, 소셜네트워킹서비스(SNS) 등을 활용한 온라인 조사에서도 최근 부각받고 있다.
- 그러나 이론적 결함은 분명하다. 사람들은 대체로 유유상종(homophily)하다보니 아무리 소개를 받더라도 근본적으로 성격이 유사한 하나의 덩어리만 표집하기 쉽다.

비확률표집

네번째로 모집단 비율과 표본 비율만 일치시키는 접근방법이 있다.

- 이른바 할당표집(quota sampling)은 모집단의 특성에 따른 구성비율을 미리 조사한 뒤, 그에 일치하게끔 표본의 특성별 구성비율을 유지시키는 방식이다.
- 가령 모집단에서 성별, 연령대별, 교육수준별로 구성비율이 (센서스 자료 등을 통해) 알려져 있을 때, 표본에서의 성별, 연령대별, 교육수준별 구성비율도 그와 똑같게 유지하는 것이다.
- 할당표집은 그럴듯하게 들려도 (구성비율만 따질 뿐 표본 자체가 어떻게 수집되는가는 고려하지 않으므로) 근본적으로 편의표본과 큰 차이가 없다. 즉 할당표집은 확률표집이 아님에 주의해야 한다.

비확률표집

- 할당표집은 사회조사방법론 분야에서 나름 흥미로운 역사를 가지고 있다. Babbie (2021: 293–294)에서 소개된 갤럽의 Harry Truman과 Thomas Dewey 대선 예측 실패는 굉장히 유명한 사례이다.
- 할당표집 또한 온라인 조사가 활성화되면서 다시 주목받고 있는 비확률표집이다. 종종 할당표집을 사용하면서 표본 크기를 크게 늘림으로써 정당성을 내세우는 경우가 있다. 그러나 (반복해서 강조하지만) 웹 서베이(web survey)인가 혹은 얼마나 큰 표본 크기인가와 상관없이 이것은 비확률표집이다.
- 할당표집으로 수집된 사회조사 자료가 여기저기 보이는데, 받아들일 때는 위와 같은 이유로 인해 주의해야 한다.

비확률표집

표 9-1 확률 표집과 비확률 표집의 특징 비교

특징	확률 표집	비확률 표집
모집단에서 표본추출 기회	동등함	동등하지 않음
표본추출 과정	무작위로 비의도적임	인위적이거나 의도적임
모수 추정 가능성	추정 가능함	추정 불가능함
오차 측정 가능성	측정 가능함	측정 불가능함
시간과 비교	상대적으로 많이 소요됨	상대적으로 절약할 수 있음

자료: 이창희 외(2010)의 내용을 일부 수정함.