사회조사방법론
자료 분석과 결과 해석

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

May 23, 2022

진행 순서

1. 통계분석 기법 리뷰
2. 교차표 분석과 χ^2 검정
3. 신뢰도 검정과 크론바흐 알파
4. 평균비교와 t 검정

통계분석 기법 리뷰

통계분석 기법 리뷰

- 오늘은 집중적으로 그 동안 공부한 사회통계학의 주요 분석기법을 살펴본다. 예전 강의안 등을 충실히 복습해 두어야 좋은 분석을 수행할 수 있다.
- 특히 다음을 익숙하게 사용할 수 있도록 하자.

(1) 교차표 분석(cross-tabulation analysis)과 χ^2 검정(chi-square test)
(2) 신뢰도 검정(reliability test)과 크론바흐 알파(Cronbach's α)
(3) t 검정(t test)
(4) 일원분산분석(one-way ANOVA)
(5) 상관분석(correlation analysis)
(6) 회귀분석(regression analysis)

통계분석 기법 리뷰

		종속변수(무조건 1개)	
		범주형	숫자형
독립변수	범주형(2개)	카이제곱 검정 (χ^2 test)	t 검정 (t test)
	범주형(2개 이상)		일원분산분석 (One-way ANOVA)
	숫자형(1개)		상관분석(Correlation analysis) 단순회귀분석(Simple regression analysis)
	숫자형(2개 이상)		다중회귀분석 (Multiple regression analysis)

통계분석 기법 리뷰

- 통계분석의 목적은 크게 둘로 나뉘어 기술통계(descriptive statistics)와 추론통계(inferential statistics)로 볼 수 있다.
- 기술통계는 자료 검토 단계에서도 이미 수행했으나 그 단계에서는 다소 비공식적이고 비체계적으로 이루어진다.
- 하지만 분석 단계에서 수행하는 기술통계는 (아무래도 최종적인 보고를 목적으로 하므로) 좀 더 깨끗한 표와 그림을 산출해내야 한다.
- 추론통계는 자신의 가설을 입증하기 위해 보다 t-검정이나 회귀분석과 같은 통계분석 기법을 활용하는 단계이다.
- 추론통계의 핵심은 표본 안에서 발견한 패턴이 모집단으로도 일반화(generalization)될 수 있는가의 문제에 있다. 그러므로 유의확률(p-value) 또는/그리고 신뢰구간(confidence interval)을 종종 함께 보고해야 한다.

통계분석 기법 리뷰

- 분석 기법을 연습하기 위한 차원에서라도 모두 한 번씩 사용해보도록 하자. “아 이런 식으로 활용될 수 있구나” 하는 인상을 형성하는 것이 중요하다.
- 분석의 초보자는 기법을 그저 평면적으로 적용한다. 다시 말해, 자신의 연구가설에 따라 회귀분석을 한 번 수행하고 그 결과를 해설한 뒤, 연구 보고서의 끝을 맺는다.
- 그러나 숙련자는 기법을 다차원적으로 활용한다.
- 연구가설을 지지하는 방향으로 증거를 얻었더라도 다른 경쟁하는 설명들(competing explanations)을 배제하기 위해 추가적으로 분석한다.
- 연구가설을 지지하지 않는 증거를 얻었다면 왜 그런지를 알아내기 위해 추가적으로 분석한다.

교차표 분석과 χ^2 검정

교차표 분석과 χ^2 검정

두 개의 질적변수 사이의 관계를 분석할 때는 우선 교차표를 살펴본다.

- 교차표(cross-tabulation)는 여러가지로 별칭을 가지고 있고 분할표(contingency table)라고도 종종 불린다.

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	356	165	521

- 교차표 내용이 원점수 그대로인 상태에서는 해석이 다소 모호하다.
- 그런데 우리는 관습에 따라 종종 독립변수 X에 해당하는 부분을 행(row)에 놓고, 종속변수 Y에 해당하는 부분을 열(column)에 놓는다.

교차표 분석과 χ^2 검정

- 이 경우 행 합계(row total)로 표준화하는 편이 해석에 편리하다(Why?)

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	356	165	521

	비종교인	종교인	합계
남자	0.77	0.23	1
여자	0.56	0.44	1
합계	0.68	0.32	1

- 해석은 조건부확률(conditional probability) 개념을 사용하고 있다.
- 이를 독립변수와 종속변수의 의미와 엮어 생각해보자.

$$P(\text{비종교인}|\text{남자}) = 0.77 \qquad P(\text{종교인}|\text{남자}) = 0.23$$
$$P(\text{비종교인}|\text{여자}) = 0.56 \qquad P(\text{종교인}|\text{여자}) = 0.44$$

교차표 분석과 χ^2 검정

χ^2 독립성 검정은 두 범주형 변수의 연관성을 분석하는 대표적 기법이다.

- (단일 모분산에 관한 가설검정에 사용했던) χ^2 분포를 따르는 확률밀도함수 (probability density function; PDF)를 정의하기 위해서는 독립성 가정 (independence assumption)이 필요했었다.
- Karl Pearson이 개발한 χ^2 독립성 검정(chi-square test of independence)은 이 가정을 절묘하게 이용해 (교차표에 주어진) 두 변수가 서로 독립적 (independent)인가 가설검정을 수행한다.
- 즉, 독립성을 가정하고 이론적으로 계산한 기대빈도(expected frequency) E와 실제 교차표의 관찰빈도(observed frequency) O를 비교하여 너무 큰 차이가 나는지 살펴보는 것이다.

교차표 분석과 χ^2 검정

기대빈도 E는 χ^2 분포의 독립성 가정에 따라 계산된다.

- 표준화된 자료가 아니라 원자료로 χ^2 독립성 검정을 시작한다.

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	356	165	521

- 성별과 종교 두 변수가 독립적이라면(=다른 모집단에서 나온 표본이라면) 곱셈법칙이 성립한다.

$$P(A \cap B) = P(A|B) \cdot P(B) = P(A) \cdot P(B)$$

- e.g., $P(\text{여자} \cap \text{종교인}) = P(\text{여자}) \cdot P(\text{종교인}) = (221/521) \cdot (165/521) \approx 0.13434$
- $n = 521$ 이므로 "여자 $\cap$ 종교인" 사건의 기대빈도 E는 $521 \cdot 0.13434 = 69.99$이다.

교차표 분석과 χ^2 검정

- 이제 채워진 관찰빈도 O와 기대빈도 E를 곰곰히 비교해보자!

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	165	356	521

	비종교인	종교인
남자	204.99	95.01
여자	151.01	69.99

- 기대빈도 E는 두 변수가 독립적이라는 가정에 입각했을 때 이론적으로 기대된 빈도였다.
- 다시 말해, 기대빈도 E가 관찰빈도 O와 크게 다르지 않다면 독립성 가정(=두 변수는 서로 독립적이다)는 결론에 도달한다.
- 반면, 기대빈도 E와 관찰빈도 O가 크게 다르다면 독립성 가정이 틀리다는 결론에 도달한다. 즉 두 변수는 연관되어 있는 것이다.

교차표 분석과 χ^2 검정

지금까지 논의를 통해 χ^2 분석의 가설구조를 유추할 수 있다.

- χ^2 독립성 검정의 가설은 다음과 같다.

$$H_0 : \text{성별과 종교인 여부는 서로 독립적이다.}$$
$$H_a : \text{성별과 종교인 여부는 서로 독립적이지 않다.}$$

- 만일 귀무가설을 기각할 수 있었다고 할지라도 여성이 더 종교적인지 여부 등은 독립성 검정을 통해서는 알 수 없다.
- 단지 "성별과 종교성이 서로 독립적"이라는 귀무가설을 통계적으로 유의하게 기각할 수 있을 뿐이다.
- 대립가설 이상의 해석을 χ^2 독립성 검정에 멋대로 덧붙이지 않도록 꼭 주의해야 한다!

교차표 분석과 χ^2 검정

이제 (가설검정을 위한) 검정통계량을 계산한다.

- 검정통계량인 χ^2 값은 다음과 같이 계산된다.

$$\chi^2_{(j-1)(k-1)} = \sum_{j=1}^{J}\sum_{k=1}^{K}\frac{(O_{jk}-E_{jk})^2}{E_{jk}}$$

- 여기서 j와 k는 각각 교차표의 행과 열의 수, O_{jk}와 E_{jk}는 각각 j번째 행, k번째 열의 관찰빈도 O와 기대빈도 E를 의미한다.
- 앞의 예에서는 2×2 교차표였으므로 $J = K = 2$다. 자유도는 $(j-1)(k-1) = 1$이다. 그만큼의 자유도를 가진 χ^2 분포를 그린다.
- 만일 귀무가설대로 $O = E$라면 χ^2는 0이다. 그러나 표본에서 계산된 χ^2 값이 크다면 (그려진) χ^2 분포 위의 아주 구석진 곳에 놓일 것이다.

교차표 분석과 χ^2 검정

예제 1. religious.csv를 SPSS로 불러와 교차표를 만들고 χ^2 독립성 검정을 수행하여 두 변수 간 연관성에 대해 설명하시오.

교차표 분석과 χ^2 검정

지금까지는 두 변수 "모두" 양적 변수이거나 질적 변수인 경우를 다루었지만, 양적 변수와 질적 변수의 연관성도 쉽게 분석할 수도 있다.

- 첫번째 방법은 정보의 손실을 각오하고 양적 자료를 질적 자료로 변환(recoding)하는 것이다.
- 일정 정도 정보의 손실(loss of information)이 발생하지만 해석이 보다 직관적이라면 이 방법이 가장 괜찮을 수도 있다.
- 조금 더 생각해보면, 사실 두 양적 변수 사이의 관계라도 얼마든지 교차표로 분석할 수 있음을 알 수 있다.

교차표 분석과 χ^2 검정

- 사업장 규모에 따라 각종 안전보건관리 조직 및 구성이 상이할까?

<표 2> 사업장 규모에 따른 안전보건조직 및 구성의 차이

사업장 안전보건관리 조직 및 구성	실태	사업장 규모(상시근로자 수)				전체	$\chi 2$
		-49인	50-99인	100-299인	300인-		
안전보건관리 조직 구성	미구성	40 (11.7)	227 (20.3)	166 (14.3)	29 (8.3)	462 (15.6)	38.156***
	구성	303 (88.3)	893 (79.7)	992 (85.7)	320 (91.7)	2508 (84.4)	
사업장내 안전관리자 선임형태	비전담 및 대행	107 (31.2)	833 (74.4)	689 (59.5)	122 (35.0)	1751 (59.0)	302.489***
	전담	236 (68.8)	287 (25.6)	469 (40.5)	227 (65.0)	1219 (41.0)	
안전보건 관리시스템 또는 대처방안 마련	그렇지 않다	56 (16.3)	159 (14.2)	94 (8.1)	36 (10.3)	345 (11.6)	29.085***
	그렇다	287 (83.7)	961 (85.8)	1064 (91.9)	313 (89.7)	2625 (88.4)	

*** $p<0.001$

최서연. 2019. "사업장의 안전보건활동이 안전문화 정착에 미치는 영향: 사업장 규모를 중심으로." 인문사회 21 10(4): 1105-1118.

신뢰도 검정과 크론바흐 알파

신뢰도 검정과 크론바흐 알파

측정오차는 실증 연구에 있어서는 불가피한 요소이다.

- 실증적인 사회학 연구는 사회 현상을 관찰하여 이를 관찰되고(observed) 측정된(measured) 자료로 표현한다. 이 과정에서 이론적 구성물(theoretical construct)이라는 관념이 등장한다.
- 이론적 구성물은 "그 자체로는 직접 관찰가능하지 않고 오로지 관찰되고 측정된 자료를 통해 간접적으로 유추될 수 있는 관념"을 뜻한다.
- 이론적 구성물을 측정하기 위해서는 적어도 둘 이상의 측정항목으로 이루어져 있는 것이 보통이다. 하나의 질문만으로 특정 개념을 단번에 측정하기 어렵기 때문이다.
- 그러나 여러 문항들을 사용하다보면 문항 간의 일관성(consistency)이 의심스러울 수 밖에 없다.
- 사회조사의 맥락에서 내적 신뢰도(internal reliability)는 일관성을 확인하기 위한 확인 절차이며, 크론바흐 알파(Cronbach's α)가 가장 널리 사용된다.

신뢰도 검정과 크론바흐 알파

크론바흐 알파에 앞서 신뢰도 비율 ρ의 논리를 이해해야 한다

- 먼저 오차(error) e란 실제로 측정된 값(observed score) X와 (연구자가 측정하고자 하는) 참 값(true score) T 사이의 괴리를 뜻한다.

$$X = T + e$$

- 몇 가지 가정에 따라 다음이 성립한다(증명 생략)

$$Var(X) = Var(T) + Var(e)$$

- 한편 신뢰도 비율(reliability ratio) ρ는 다음과 같이 정의된다.

$$\rho = \frac{Var(T)}{Var(X)} = 1 - \frac{Var(e)}{Var(X)}$$

신뢰도 검정과 크론바흐 알파

- 여러 개의 측정항목들 $X_1, X_2, \cdots, X_k$ 을 모두 더하거나 평균을 내 합성지수 (composite index) Y 를 만든다고 하자.
- (과녁판의 비유에서 살펴보았듯) 개별 측정항목 X 의 높은 분산 σ_X^2 은 곧 해당 측정항목의 높은 불확실성을 의미한다.
- 그러므로 개별 측정항목들의 분산합 $\sum \sigma_X^2$ 은 결국 사용된 측정항목들의 전반적인 불확실성을 반영한다!
- 그러므로 만약 잠재변수의 전체 분산 σ_Y^2 에서 개별 측정항목들의 분산합 $\sum \sigma_X^2$ 의 비중이 크다면 이는 "일관되지 않은" 개별 측정항목들로 그 합성지수를 만든 것이므로 (그 합성지수는) 신뢰도가 낮다고 할 수 있다.

$$\rho = \frac{\sigma_y^2 - \sum \sigma_{X_i}^2}{\sigma_y^2} = 1 - \frac{\sum \sigma_{X_i}^2}{\sigma_y^2}$$

신뢰도 검정과 크론바흐 알파

크론바흐 α는 (변수가 늘어나는 것에 약간 패널티를 준) 신뢰도 비율이다.

- α는 합성지수를 구성하는데 사용한 변수의 수 k로 적절히 가중된 신뢰도 비율이다.

$$\alpha = \left(\frac{k}{k-1}\right)\left(1 - \frac{\sum s_{X_i}^2}{s_y^2}\right)$$

- 분자에 들어간 $\sum S_X^2$ 가 S_y^2 보다 상대적으로 커지면 α는 감소한다(Why?).
- α는 0에서 1사이에 놓인 값을 갖는다. 1에 가까울수록 내적 일관성이 높다(Why?). 관행상 0.7보다 높으면 대체로 문제가 없는 것으로 판단한다.
- 경우에 따라 새로운 측정문항을 추가하거나 기존 측정문항을 빼서 α 점수를 높일 필요가 있을 수도 있다.

교차표 분석과 χ^2 검정

예제 2. Y1_STD_EDU.SAV를 SPSS로 불러와 사회적 자아(social self)의 합성지수를 만들고 이것의 크론바흐 α를 구한 다음, 그 의미를 해석하시오.

평균비교와 t 검정

평균비교와 t 검정

살펴보려는 모집단이 두 개 있다면 그 평균의 차이에 관해 가설검정할 수 있다.

- 이른바 평균비교(mean comparison)에서는 각각의 모집단에서 무한히 표본을 계속 뽑고 두 평균의 차 $\bar{x}_1 - \bar{x}_2$를 확률변수(random variable)로 보아 표집분포를 그릴 수 있다.
- 중심극한정리 덕택에 그 표집분포는 대표본일 때 정규분포한다(증명 생략). 물론 소표본이라면 t 분포한다.
- 이제 귀무가설을 세우고 적절하게 가설검정을 수행할 수 있다. 다만 자료구조에 따라 (2) 독립표본 t 검정(t test for independent samples) 또는 (3) 쌍체표본 t 검정(t test for paired samples)을 사용해야 한다.

평균비교와 t 검정

평균비교는 두 모집단의 평균의 차이를 가설검정의 대상으로 삼는다.

- 평균비교는 양측검정과 단측검정으로 수행될 수 있다.

$$H_0 : \mu_1 - \mu_2 = 0 \qquad H_0 : \mu_1 - \mu_2 \geq 0 \qquad H_0 : \mu_1 - \mu_2 \leq 0$$
$$H_a : \mu_1 - \mu_2 \neq 0 \qquad H_a : \mu_1 - \mu_2 < 0 \qquad H_a : \mu_1 - \mu_2 > 0$$

- 사실 0이 아닌 숫자로 가설검정을 할 수 있다. 하지만 0이 실무나 연구에서 많이 쓰이므로 이렇게 알아두어도 괜찮다.

평균비교와 t 검정

인문사회·공학·보건의료 등 여러 분야에서 평균비교는 매우 유용하다!

- 남성의 연 평균소득(μ_1)과 여성의 연 평균소득(μ_2)의 차이
- 전업 공연예술인의 예술지원정책 만족도(μ_1)과 비전업인의 정책 만족도(μ_2)의 차이
- 진중문고 독서지도 프로그램을 이수한 군장병의 복무의욕(μ_1)과 그렇지 않은 군장병의 복무의욕(μ_2)의 차이
- 가출경험이 있는 중학생이 가진 비행경험 친구의 수(μ_1)와 가출경험이 없는 중학생이 가진 비행경험 친구의 수(μ_2)의 차이
- 집중강화 트레이닝을 받기 전 2군 선수들의 이전 평균기록(μ_1)과 이후 평균기록(μ_2)의 차이
- 처방약을 복용한 환자의 혈압(μ_1)과 위약을 복용한 환자의 혈압(μ_2)의 차이

평균비교와 t 검정

독립표본 t 검정과 쌍체표본 t 검정은 어떻게 다른가?

- 이것은 데이터가 어떻게 생겼는가로 쉽게 이해할 수 있다.
- 왼쪽은 쌍체표본(paired samples)으로 같은 사람에 대해 처방 전후(before and after)로 기록이 짝지어(paired) 있는 반면, 오른쪽은 독립표본(independent samples)은 처방(treatment) 실시 여부를 말해주는 더미변수(dummy variable)가 있다.

ID	BEFORE	AFTER
1	35	27
2	31	39
3	46	33
4	39	40
5	31	31

ID	TREATED	RECORD
1	0	35
2	0	31
3	0	46
4	0	39
5	0	31
1	1	27
2	1	39
3	1	33
4	1	40
5	1	31

평균비교와 t 검정

예제 3. Y1_STD_EDU.SAV를 SPSS로 불러와 사회적 자아(social self)의 합성지수를 만들고 이것의 성차에 관한 가설검정을 수행하시오. 그 결과를 논하시오.