사회조사방법론
발견의 요약과 정리

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

May 30, 2022

진행 순서

1. 일원분산분석
2. 상관분석
3. 회귀분석
4. 회귀모형의 적합도

일원분산분석

일원분산분석

일원분산분석을 복습하기 위해 그보다 더 기초를 복습해야 한다.

- 단일 모분산에 관한 가설검정과 관련하여 χ^2 분포(chi-square distribution)를 먼저 공부하였고, 두 모분산의 가설검정과 관련하여 F 분포(F distribution) 분포를 다음으로 공부하였다.
- 그 뒤, 둘 이상의 집단의 분산을 비교하는 원리를 제시하는 일원분산분석의 수리적 모형을 공부하였다.
- 최종적으로 위 수리모형을 F 분포에 따라 가설검정하였다.

일원분산분석

분산에 대해서도 표집분포를 상상할 수 있다.

- 우리는 모집단에서 표본을 무한히 계속 뽑고 그것들의 분산 s^2를 구해 분산의 표집분포(sampling distribution of the variance)를 상상할 수 있다.
- 평균 $\bar{x}$의 표집분포인 경우 소표본일 때 t 분포, 대표본일 때 Z 분포라는 이론적 확률분포를 가졌다.
- 반면 분산 s^2의 경우 직접적인 이론적 확률분포가 없고, 표본분산 s^2와 모분산 σ^2 간의 비율(ratio)에 관한 이론적 확률분포인 χ^2 분포를 대신 사용한다.

$$\chi^2_{n-1} = \frac{(n-1)s^2}{\sigma^2}$$

일원분산분석

- χ^2 분포는 자유도 $n-1$에 의해 모양이 결정된다.
- χ^2 분포는 소표본일 때 비대칭적이고 오른쪽으로 꼬리가 길다(Why?). 여기서 증명하지는 않지만 사실 다음이 성립한다. 이렇게 제곱을 하다보면 우연히 큰 값이 나타나기 쉽고 표본이 작다보면 그 값이 튀어보인다.

$$\chi_k^2 = Z_1^2 + Z_2^2 + \ldots + Z_k^2 = \sum \left(\frac{x-\mu}{\sigma}\right)^2$$

- χ^2 값은 결국 분산들의 비율이므로 항상 양수값을 갖는다.

$$\frac{s^2}{\sigma^2} \geq 0$$

- 그러나 대표본이 될수록 정규분포의 모습에 점점 근사한다(Why?).

일원분산분석

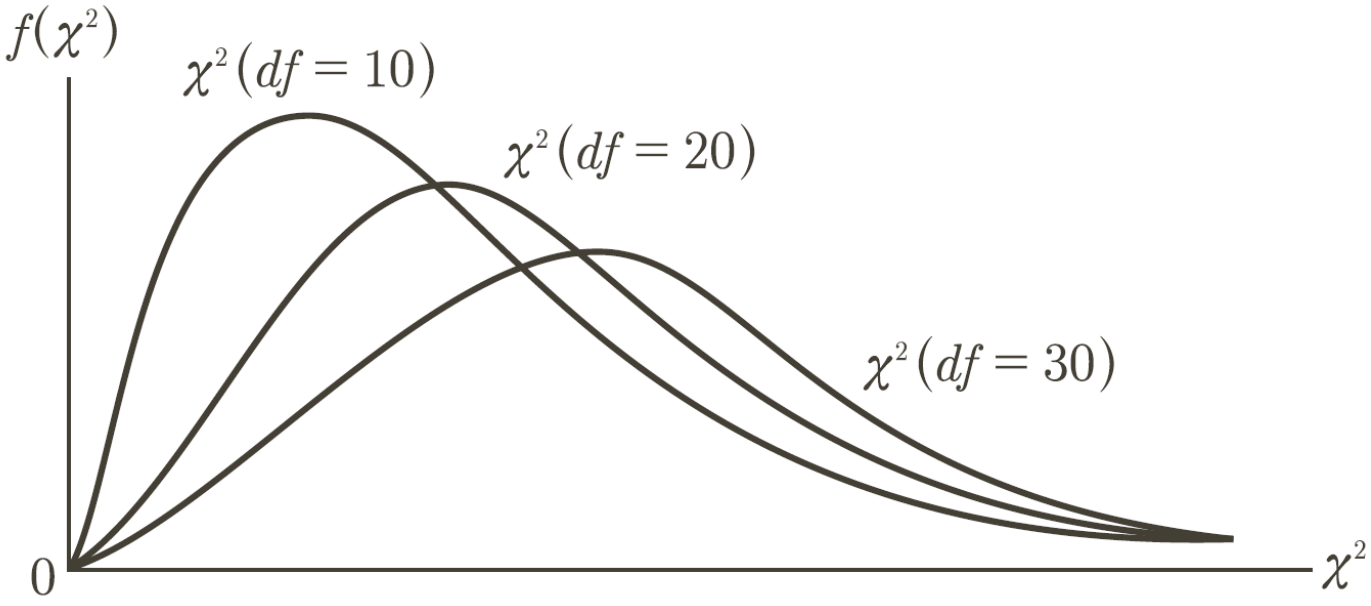

일원분산분석

모분산에 관해서도 두 가지로 가설검증 방식이 있다.

- 만약 모집단이 "하나" 있다고 하자. 이것의 분산의 표집분포가 χ^2 분포를 따른다고 할 때, 귀무가설을 나의 표본에 따라 기각할 수 있는가 살펴볼 수 있다. 이것이 단일표본 χ^2 검정(one-sample chi-square test)이다.
- 만약 모집단이 "두 개" 주어졌다고 하자. 두 모집단 분산의 비율의 표집분포가 F 분포(F distribution)를 따른다고 할 때, 귀무가설을 나의 표본에 따라 기각할 수 있는가 살펴볼 수 있다. 이것을 F 검정(F test)이라고 부른다.
- 말하자면 분산비교(variance comparison)도 평균비교(mean comparison)처럼 수행할 수 있는 셈이다.

일원분산분석

분산비교는 F 분포에 기반하여 수행된다.

- "단일모집단의 분산"에 관한 가설 검정이 χ^2 분포를 이용하는 반면, "두 모집단의 분산의 비율"에 관한 가설 검정은 F 분포를 이용한다(교과서 190).
- F 분포의 확률밀도함수(probability density function; PDF)는 다음과 같이 정의된다.

$$F_{(n_1-1,n_2-1)} = \frac{\chi_1^2/(n_1-1)}{\chi_2^2/(n_2-1)}$$

- 조금만 생각해보면 F 분포는 각각의 "단일모집단의 분산"을 설명하는 χ^2 두 개의 비율임을 쉽게 파악할 수 있다. 다만 자유도를 사용하여 약간의 보정이 이루어졌을 뿐이다.

일원분산분석

- 우리는 두 표본의 분산의 차(difference)를 구하려는 것이 아니라 비(ratio)를 구하려는 것이므로 두 χ^2 값이 서로 비슷할수록 F 값은 (0이 아니라) 1에 접근하리라 예상할 수 있다.
- F 값은 두 개의 χ^2 분포의 비로 구성되므로 항상 양수(+)이다.
- F 분포는 두 개의 자유도 $n_1 - 1$와 $n_2 - 1$를 패러미터(parameter)로 받아 그 형태가 결정된다. 이것도 χ^2가 하나의 자유도 $n - 1$를 파라미터로 받아 그 형태가 결정되는 것과 유사하다.
- 두 개의 자유도가 작을 때는 우측 꼬리가 길다. 두 개의 자유도가 점점 커지면 정규분포에 점점 근사한다.
- χ^2 분포와 마찬가지로 대칭적인 형태가 아니다.
- 일단 χ^2 분포 자체에 익숙해져야 F 분포에 대해서도 쉽게 이해할 수 있다.

일원분산분석

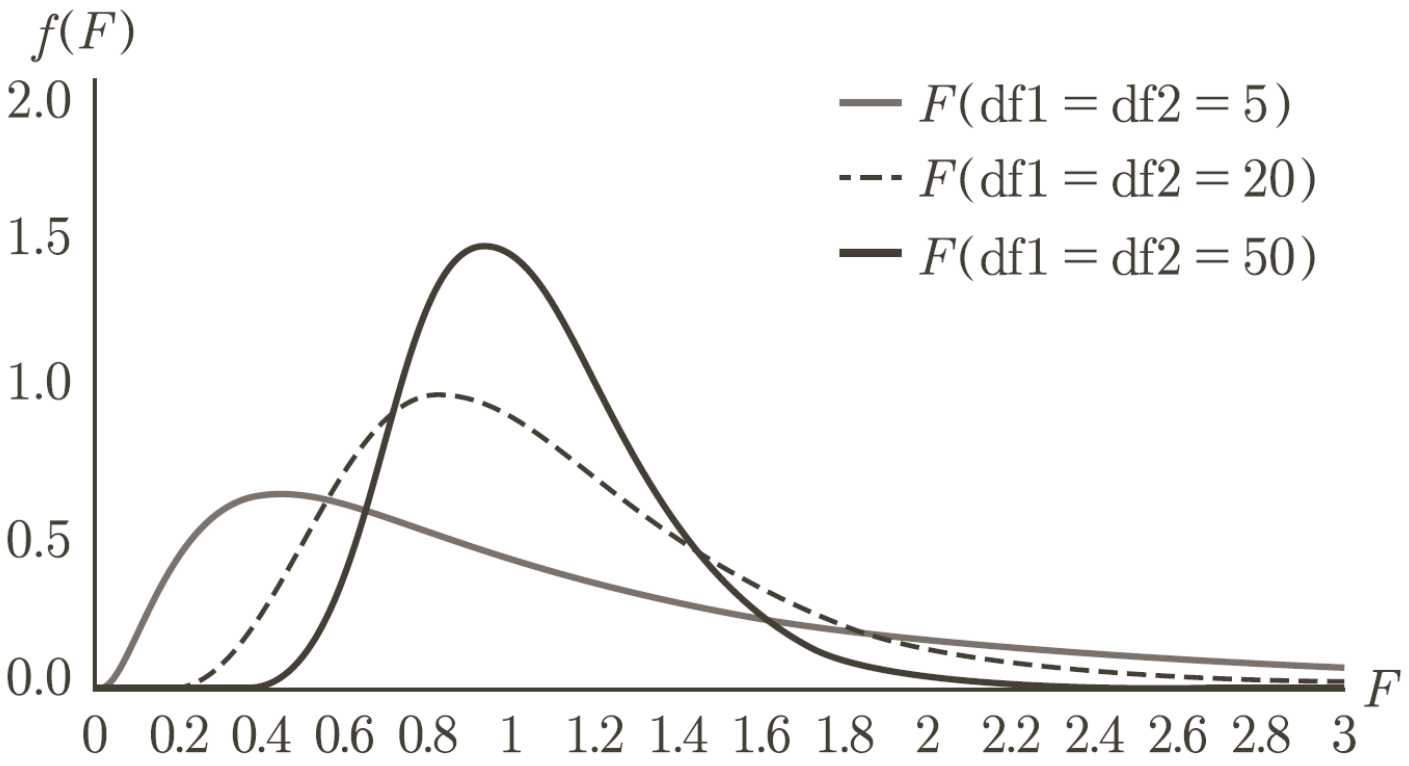
$f(F)$
2.0
1.5
1.0
0.5
0.0
0 0.2 0.4 0.6 0.8 1 1.2 1.4 1.6 1.8 2 2.2 2.4 2.6 2.8 3
F
$F(\mathrm{df1} = \mathrm{df2} = 5)$
$F(\mathrm{df1} = \mathrm{df2} = 20)$
$F(\mathrm{df1} = \mathrm{df2} = 50)$

일원분산분석

검정통계량 F 값을 계산할 때 몇 가지 주의할 점이 있다.

- 우리가 추정하고자 하는 것은 두 모집단의 분산 비율 σ_1^2/σ_2^2 임을 기억해야 한다.
- 정규분포하는 두 모집단에서 서로 독립인 임의표본을 추출한 뒤, 모분산(population variance)의 불편추정량 s_1^2과 s_2^2를 다음과 각각 같이 계산한다.

$$s_1^2 = \frac{\sum(x_{1i} - \bar{x}_1)^2}{n_1 - 1}, \qquad s_2^2 = \frac{\sum(x_{2i} - \bar{x}_2)^2}{n_2 - 1}$$

- 그러면 자연스럽게 F 값은 다음과 같이 단순화된다(Why?).

$$F_{(n_1-1,n_2-1)} = \frac{s_1^2}{s_2^2}$$

일원분산분석

- 검정통계량 F 값은 비율이기 때문에 어느 쪽이 분자가 되는지 주의해야 한다.
- 많은 교과서에서 분산이 큰 쪽을 반드시 분자로 놓도록 가르친다. 그러면 반드시 F 값은 1보다 커지므로 양측검정은 사라지고 오로지 단측검정만 생각하면 된다(Why?).
- 분자분모 설정에 따라 분산비교를 위한 F 검정의 가설구조는 오로지 우측 단측검정만을 따르게 된다.

$$H_0 : \frac{\sigma_1^2}{\sigma_2^2} \leq 1$$

$$H_a : \frac{\sigma_1^2}{\sigma_2^2} > 1$$

일원분산분석

F 검정에서도 마찬가지로 유의성 검정을 수행할 수 있다.

- 가장 먼저 모분산 비율 σ_1^2/σ_2^2에 대한 귀무가설 및 대립가설을 설정한다. 분자분모를 주의깊게 고르면 가설구조는 늘 똑같다.
- (정규분포한다고 가정된) 모집단으로부터 작은 표본을 뽑는다. 자유도 두 개 df_1, df_2, 표본분산 비율 S_1^2/S_2^2, (귀무가설로 설정된) 모분산 비율 σ_1^2/σ_2^2에 따라 F 값, 즉 검정통계량을 계산한다.
- 이 검정통계량이 (자유도 두 개에 따라 형태가 결정된) F 분포 위 어디에 위치해 있는가에 따라 유의확률(p-value)을 계산할 수 있다.
- 주어진 유의수준에 따라 귀무가설을 기각할 수 있는지 확인하고 결과를 보고한다.

일원분산분석

간단한 예제를 통해 일원분산분석의 논리를 살펴보자.

- 다음과 같은 (극단적으로 단순한) 모집단이 있다고 상정하자.

처리집단1	처리집단2	처리집단3	
$Y_{11} = 2$	$Y_{12} = 3$	$Y_{13} = 3$	
$Y_{21} = 2$	$Y_{22} = 2$	$Y_{23} = 2$	
$Y_{31} = 5$	$Y_{32} = 1$	$Y_{33} = 7$	
$\mu_1 = 3$	$\mu_2 = 2$	$\mu_3 = 4$	$\mu = 3$

- 가령 Y_{11}, Y_{21}, Y_{31}은 처리집단1의 평균 μ_1과 (약간의) 오차항 e_{i1}의 합으로 설명된다. 즉, $Y_{i1} = \mu_1 + e_{i1}$이다.
- 처리집단1의 평균 μ_1이 곧바로 처리효과가 되는 것은 아니다. 처리효과는 처리집단1의 평균 μ_1과 총평균 μ의 차이로 나타난다(Why?). 즉, $\alpha_1 = \mu_1 - \mu$이다.
- 그러므로 $Y_{i1} = \mu_1 + e_{i1} = \mu + \alpha_1 + e_{i1}$이다.

일원분산분석

일원분산분석은 매우 단순한 논리 구조를 가지고 있다.

- 일원분산분석의 모집단에 관한 수리모형은 다음과 같다.

$$Y_{ij} = \mu_j + e_{ij}$$

- 이때 e_{ij}는 오차항(error term)이다. 오차는 무작위적(random)이라고 가정된다.
- 처리효과(treatment effect)는 $\alpha_j = \mu_j - \mu$이므로(Why?),

$$Y_{ij} = \mu + \alpha_j + e_{ij}$$

- 다시 말해, (종속변수가 되는) 모집단 개체의 관찰값 Y_{ij}은 전체 평균 μ와 처리효과 α_j, 그리고 오차항 e_{ij}으로 분해된다.

일원분산분석

- 우리가 보고 있는 결과인 Y_{ij}은 사실 그룹 간(between) 처리효과 α_j의 산물일 뿐만 아니라, (처리와는 별개로 우리 모두가 나름대로 가진) 일종의 출발선(baseline)이라고 할 수 있는 총평균 μ과 그룹 내(within) 개별적인 오차 e_{ij}로부터도 영향을 받아 나타난 것이다!

$$y_{ij} = \mu + \alpha_j + e_{ij}$$

- 이제 위 식을 살짝 변경하면 일원분산분석의 핵심을 모두 파악할 수 있다.

$$\begin{aligned} Y_{ij} - \mu &= \alpha_j + e_{ij} \\ &= (\mu_j - \mu) + (Y_{ij} - \mu_j) \end{aligned}$$

- 위 식에 제곱합(sum of squares; SS)을 해도 아래와 같이 성립한다는 것은 수학적으로 증명할 수 있다(우리는 하지 않지만!).

$$\begin{aligned} \sum (Y_{ij} - \mu)^2 &= \sum (\mu_j - \mu)^2 + \sum (Y_{ij} - \mu_j)^2 \\ SS_{total} &= SS_{between} \quad + SS_{within} \end{aligned}$$

일원분산분석

- 제곱합 SS는 적절한 자유도인 $n-1$와 $k-1$ 그리고 $n-k$로 나누어 평균제곱 (mean squares; MS)이라고 부른다.

$$\frac{\sum(Y_{ij}-\mu)^2}{(n-1)} = \frac{\sum(\mu_j-\mu)^2}{(k-1)} + \frac{\sum(Y_{ij}-\mu_j)^2}{(n-k)}$$

$$MS_{total} = MS_{between} \quad + MS_{within}$$

- 그런데 이것은 각각 "분산의 불편추정량"이 된다(Why?).

$$\sigma^2_{total} = \sigma^2_{between} + \sigma^2_{within}$$

- 각각의 자유도 계산원리도 무척 단순하다(Why?). 여기서 k은 그룹의 숫자이다.

$$(n-1) = (k-1) + (n-k)$$

일원분산분석

일원분산분석의 검정통계량은 F 값이다.

- 일원분산분석은 F 분포를 사용하며, 그 근본 원리는 (앞서 설명한) 두 모집단 분산 비율에 대한 가설검정과 같다.

$$
\begin{aligned}
F_{(k-1,n-k)} &= \frac{\sigma^2_{between}}{\sigma^2_{within}} \\
&= \frac{SS_{between}/(k-1)}{SS_{within}/(n-k)} \\
&= \frac{MS_{between}}{MS_{within}}
\end{aligned}
$$

- 분자는 실험처리에 의한 효과(treatment effect)로 볼 수 있고, 분모는 무작위오차(random error)에 지나지 않는다(Why?).

일원분산분석

집단 간 분산이 클수록 그리고 집단 내 분산이 작을수록 F 값은 커진다.

- 수리적으로 따지고 들어갈 필요조차 없다. 사실 F 값이 갖는 의미는 상식적으로 너무나 명확하다!
- 두 표본이 주어졌을 때, 표본 간에는 차이가 크고 표본 내에는 차이가 작다면, 두 모집단은 서로 다른 것이다.
- 두 표본이 주어졌을 때, 표본 간에는 차이가 작고 표본 내에는 차이가 크다면, 두 모집단은 서로 다르다고 할 수 없다.
- 따라서 큰 F 값은 두 모집단은 서로 다름을 시사한다.

일원분산분석

- 집단 간(between) 차이가 크고 집단 내(within) 차이가 작은 경우

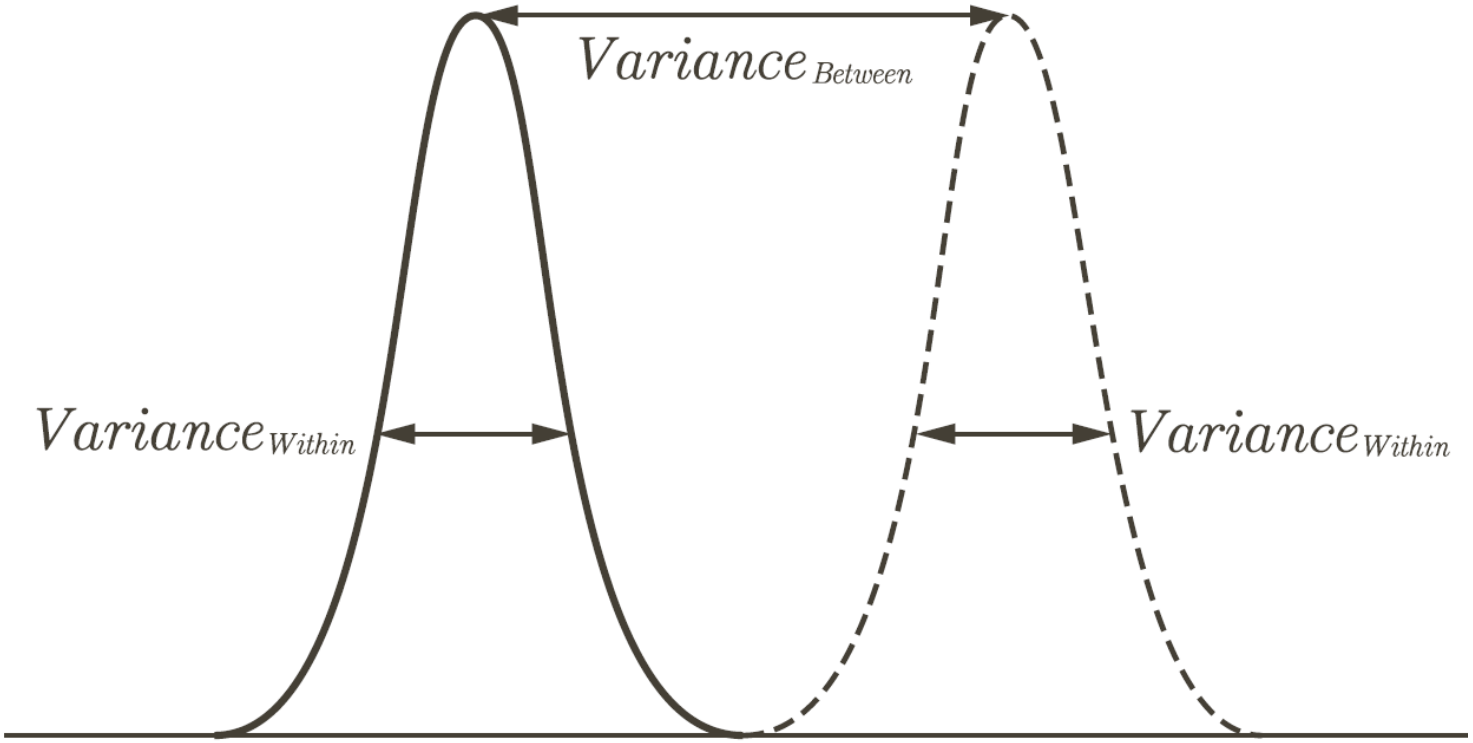

일원분산분석

- 집단 간(between) 차이가 작고 집단 내(within) 차이가 큰 경우

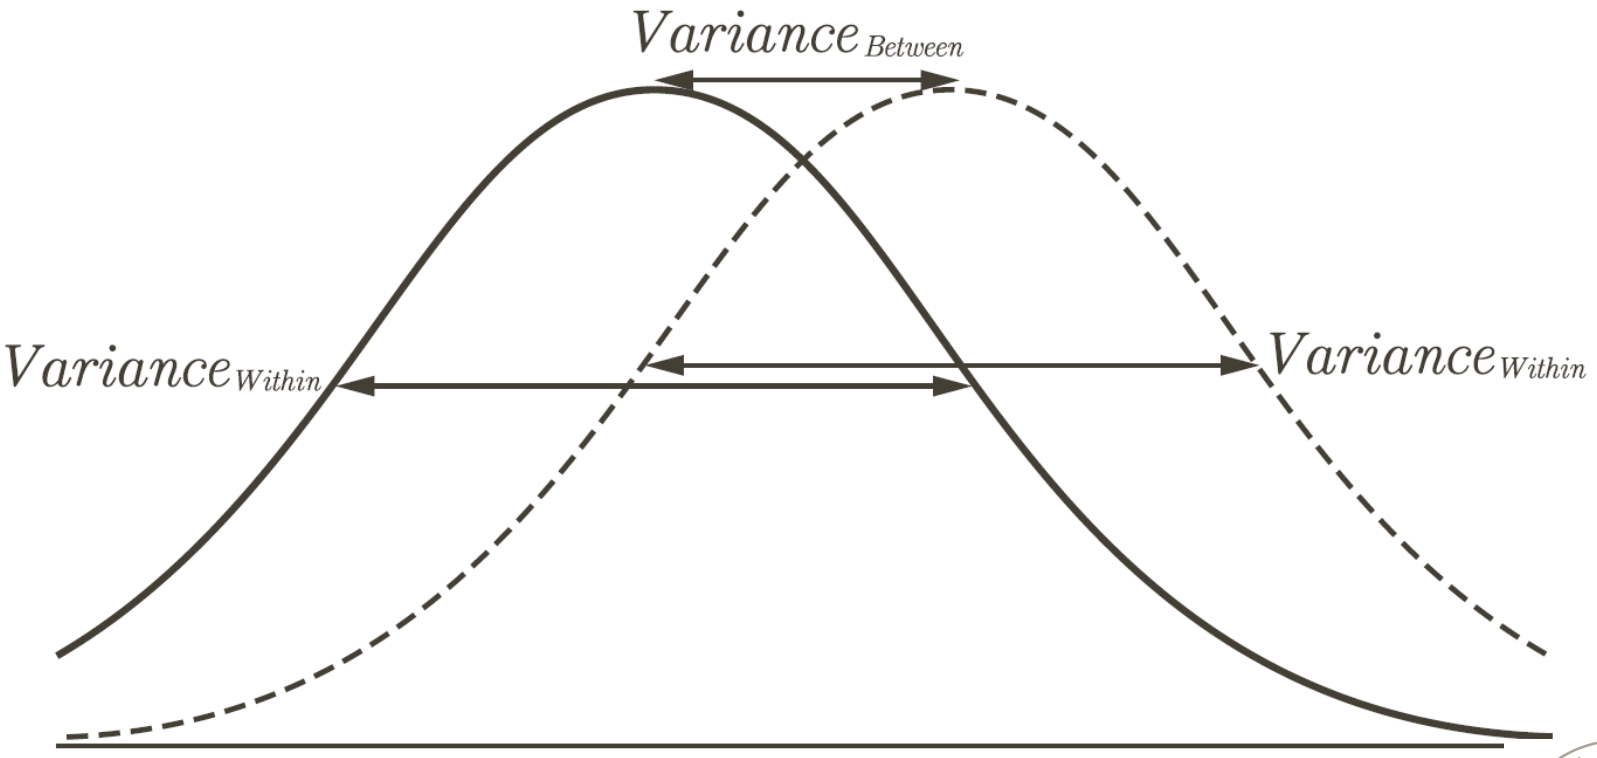

일원분산분석

- 계산을 진행하면서 분산분석표(ANOVA table) 안에 각각의 숫자를 채워넣으면 된다. 아! 물론 계산은 컴퓨터가 한다.

Variance	SS	df	MS	F
Between groups	$SS_{between}$	$(k-1)$	$MS_{between}$	F
Within groups	SS_{within}	$(n-k)$	MS_{within}	
Total	SS_{total}	$(n-1)$	MS_{total}	

- 실제 표에서는 F 옆에 유의확률(p-value)이나 임계값(critical value) 등도 추가해서 써넣는 경우도 있다.

일원분산분석

일원분산분석의 가설 설정은 다소 주의를 요한다.

- 귀무가설은 "모든 그룹에 걸쳐 평균이 같다"이다. 예를 들면 다음과 같다.

  (1) 인지된 기후변동의 심각성 점수의 평균에 최종학력별 차이는 없다.
  (2) 출신지역별로 정치적 보수주의 점수 차이가 없다.
  (2) 기업내 직급 수준에 따른 인적자원개발 프로그램 만족도 차이는 없다.

$$H_0 : \mu_1 = \mu_2 = \mu_3 = ... = \mu_k$$

- 그 대립가설은 "적어도 하나의 그룹에서 평균값이 다르다"이다.

$$H_a : (\mu_1 \neq \mu_2) \text{ or } (\mu_1 \neq \mu_3) \text{ or } ... \text{ or } (\mu_{j-1} \neq \mu_j)$$

- "모든 그룹에 있어 평균값이 다르다($H_a : \mu_1 \neq \mu_2 \neq \mu_3 = ... \neq \mu_j$)"가 아님에 주의할 것(Why?)!

일원분산분석

- 당연히 “최종학력이 높아질수록 인지된 기후변동의 심각성 점수도 함께 높아진다”와 같은 해석은 본래 일원분산분석으로 할 수 없는 과잉해석이 된다.
- 위와 같은 해석을 하기 위해서 (앞서 제시된 귀무가설을 넘어) 보다 구체적으로 두 그룹씩 짝지어 비교할 수 있다.
- 이른바 다중비교검정(multiple comparison test)은 임의로 선정된 두 그룹 중 어느 그룹에서 평균값이 더 높은가를 살펴보는 기법이다. 교과서에 따라서는 사후비교(post hoc comparison)라고 부르기도 한다. 우리는 다루지 않았다.
- 일원분산분석은 실제 분석상 분산의 비율을 비교하고 있음에도 불구하고, 가설 설정은 평균에 대해 이루어진다는 점도 주의해야 한다.

일원분산분석

예제 1. 네오청주의 시장조사기관에서 근무하는 태준은 여러 가지 미디어로부터 얻는 만족도를 비교하기 위해서 실험을 계획하였다. 40명의 성인을 랜덤하게 추출하여 철저한 면접을 통해 넷플릭스, 유튜브, 틱톡, 트위치 중 어느 매체를 많이 접하는지에 따라 분류하였다. media.sav는 조사 대상자들의 미디어 만족도를 측정한 실험에서 얻어진 값들을 나타내고, 값이 클수록 만족도가 높은 것을 의미한다. 이 자료를 상자-수염 그림(box-whisker plot)으로 시각화하고, 사람들의 만족도가 대중매체에 따라 다르다고 할 수 있는지 1% 유의수준에서 검정하라.

상관분석

상관분석

두 양적변수 사이의 관계를 살펴볼 때는 우선 상관분석을 수행한다.

- 상관계수(correlation coefficient)를 이해하려면 먼저 분산(variance)과 공분산(covariance)을 돌이켜 볼 필요가 있다.
- 먼저 분산의 식을 돌이켜보자.

$$
\begin{aligned}
Var(X) = \sigma_X^2 &= \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)(x_i - \mu)
\end{aligned}
$$

- 변수가 하나 주어져 있을 때 편차(deviation)를 구해 제곱하여 분산을 구했는데, 아래처럼 살짝 바꾸면 곧바로 공분산이 된다.

$$
Cov(X, Y) = \sigma_{XY} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu_X)(Y_i - \mu_Y)
$$

상관분석

- 공분산과 분산의 아이디어는 거의 똑같다! 다만 x_i 하나의 편차를 제곱하는 대신, x_i 와 Y_i 의 편차를 서로 곱했을 뿐이다.
- 두 변수의 편차끼리 곱할 때, 모두 양수(+)이거나 음수(-)이면 공분산은 양수(+)가 되고, 어느 한쪽이 양수(+)이고 다른 쪽이 음수(-)이면 공분산은 음수(-)가 된다.
- 공분산은 흥미로운 아이디어를 제시하고 있지만 명확한 단점이 있었다. $Cov(X, Y)$ 는 X 내부(within X)의 분산과 Y 내부(within Y)의 분산이 다를 수 있다는 점을 고려하지 않았으므로 제대로 표준화가 이루어지지 않았다.
- 그 결과 그 자체로는 해석이 어려웠기 때문에 새로운 대안이 필요했다.

상관분석

Karl Pearson은 공분산의 단점을 보완하는 천재적인 접근을 제시했다.

- 그는 두 변수 X와 Y의 각각의 표준편차(분산이 아니고!)를 분모로 각각 나누어줌으로서 X 내부의 분산과 Y 내부의 분산이 다를 수 있는 가능성을 제거하고 표준화를 이루었다.
- 뿐만 아니라, 일부러 분산이 아닌 표준편차로 나누어주었기 때문에 표준화된 값은 절묘하게 -1과 1사이로 두 변수가 얼마나 강한 상관관계를 가지고 있는지 보여준다.
- 이것이 이른바 피어슨의 적률상관계수(Pearson's product-moment correlation coefficient)이다. 줄여서 상관계수 ρ다. ρ는 rho라고 읽는다.

$$\rho = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

상관분석

상관계수의 해석은 매우 간단하지만 혼동하지 않도록 주의해야 한다.

- 상관계수는 반드시 -1과 1사이에 놓인다. $\rho = 0$는 무상관(no correlation), $\rho = 1$은 완전상관(perfect correlation)이라고 한다.
- 상관계수가 0보다 크면 두 변수는 서로 같은 방향(정방향)으로 움직인다. 즉 "X가 증가하면 Y도 증가한다."
- 상관계수가 0보다 작으면 두 변수는 서로 다른 방향(역방향)으로 움직인다. 즉 "X가 증가하면 Y는 감소한다."
- 왜 이렇게 해석되는지 공분산의 분자 $\sum(x - \mu_X)(y - \mu_Y)$를 잘 들여다보자.
- 상관계수가 1에 가까울수록 (그리고 -1에 가까울수록) 두 변수는 더욱 밀접한 상관관계를 갖게 된다.

상관분석

- 해석할 때는 0과 1 사이를 사분위수로 나누고 각각 리커트 4점 척도로 의미를 부여한다. 물론 0과 -1 사이에서도 마찬가지이다.

상관계수	상관관계의 해석
[-1, -0.75]	매우 강한 역방향
[-0.75, -0.5]	다소 강한 역방향
[-0.5, -0.25]	다소 약한 역방향
[-0.25, 0]	매우 약한 역방향
[0, 0.25]	매우 약한 정방향
[0.25, 0.5]	다소 약한 정방향
[0.5, 0.75]	다소 강한 정방향
[0.75, 1]	매우 강한 정방향

상관분석

상관계수에 대해서도 유의성 검정을 할 수 있다.

- 상관계수에 대해서는 무조건 양측검정을 수행하며, 가설 구조는 다음과 같다.

$$H_0 : \rho = 0$$
$$H_a : \rho \neq 0$$

- 귀무가설이 참이라는 가정 아래 무한히 계속 표본을 뽑아 그것들의 상관계수 r을 구해보면 이것은 t 분포를 따른다. 이때 평균 $E(r)$은 0이다.
- 이 t 분포의 꼴은 $n-2$의 자유도로 결정된다(Why?).

상관분석

- 검정통계량 t 값을 구하고 유의확률(p-value)을 계산한다.

$$t = \frac{r - \rho}{\sigma_r} = \frac{r}{\sqrt{\frac{1 - r^2}{n - 2}}} = r\sqrt{\frac{n - 2}{1 - r^2}}$$

- 이때 σ_r 은 표본상관계수의 표준오차(standard error)이다.
- 즉 (1) 표본상관계수 r가 커지고 (2) 표본 크기 n이 커질수록 t 값이 커져 귀무가설을 기각하기 쉬워진다.

상관분석

예제 2. fullauto.csv를 사용하여 모든 숫자형 변수들 price, mpg, hdroom, rseat, trunk, weight, length, turn, displ, gratio의 상관계수행렬을 만드시오.

상관분석

유의확률에 관한 정보를 요약하기 위해 이제부터 *을 붙이기로 한다.

- 유의확률이 0.001보다 작으면 상관계수 옆에 별 3개(***), 0.01보다 작으면 별 2개(**), 0.05보다 작으면 별 1개(*), 0.1보다 작으면 대거(dagger) 하나(†)를 붙일 수 있다.
- 이런 표식은 결국 "통계적으로 유의하게 귀무가설을 기각할 수 있음"을 의미한다.
- 이것은 완전히 관습의 문제이고 심지어 사람마다 다르다. 어떤 사람은 아예 붙이지 않기도 한다.
- 아까 나의 그림에서는 그냥 유의하다는 사실을 알리기 위해 별 하나로 퉁쳤다.

상관분석

소표본만 벗어나도 상관계수의 유의성 검정에 사실 큰 의미가 없다.

- 위 식을 곰곰히 들여다보면 눈치챌 수 있는 부분인데, 예컨대 $n = 50$ 정도로 작은 샘플에서 $r = 0.3$ 정도의 값만 나와주어도 이미 95% 신뢰수준에서 통계적으로 유의하다(Why?).
- 오늘날 경험적 사회과학 연구에서 $n = 50$ 짜리 연구는 없다. 게다가 $r = 0.3$는 거의 없는 수준의 상관관계에 불과하다.
- 그러다보니 상관분석의 경우에는 구태여 별을 붙이지 않는 경우도 있다.

상관분석

예제 3. fullauto.csv를 사용하여 가격(price)과 가성비(mpg) 사이의 연관성을 보여주는 산점도와 적합선을 그리시오. 이 두 변수의 관계가 국내차(domestic)와 외제차(foreign) 간에 어떻게 다른지 묘사하시오.

상관분석

상관계수를 보고할 때는 반드시 함께 산점도를 그려보아야 한다.

- 상관계수는 기본적으로 두 변수간 선형적 관계의 강도(strength of the linear relationship)를 나타내 보인다.
- 다시 말해, 두 변수 사이에 선형적이지 않은 관계, 즉 비선형적 관계(nonlinear relationship)가 있는 경우에는 상관계수가 오해를 불러온다.
- 애시당초 두 변수 사이가 U자형, 역U자형, W자형 등등이 아니라는 보장이 어디에 있을까?
- 극단치(outliers)가 있는 경우 상관계수는 여기에 민감하게 영향받음을 알 수 있다.
- 그러므로 (극단치의 존재를 식별해내기 위해서라도) 반드시 산점도를 그려보아야 한다.
- 필요하다면 극단치를 제거한 뒤에 다시 상관계수를 계산하는 것이 바람직할 수도 있다(물론 제거 여부를 사전에 꼭 밝혀두어야 한다).

회귀분석

회귀분석

독립변수 X와 종속변수 Y 사이의 관계를 선으로 나타내보자.

- 이른바 선형회귀모형(linear regression model)은 아래와 같이 일차방정식(linear equation)으로 설정할 수 있다.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- 하첨자 i가 붙어있으므로 관찰값(observation)에 따라 상이한 X_i와 Y_i, ϵ_i를 담게 된다.
- 이때 β_0를 상수(constant) 또는 절편(intercept)이라고 부르고, β_1를 기울기(slope)라고 부른다.
- 한편, β_0와 β_1를 어떻게 설정하더라도 결국 자료를 완벽하게 설명할 수는 없다. 따라서 오차항(error term) ϵ_i을 선형회귀모형에 추가한다.

회귀분석

- 우리는 이미 상관분석을 배우면서 적합선(fitting line)을 이미 그려보았다.
- 마찬가지로 주어진 자료의 X와 Y 사이에 가장 잘 맞는 직선(best-fitting straight line)을 그어 그 관계를 나타내 보일 수 있다.
- 이렇게 자료를 관통하는 하나의 선을 찾는 것이 바로 회귀분석(regression analysis)의 핵심이다.

회귀분석

오차를 전반적으로 최소화하는 적합선이야말로 가장 잘 맞는 직선이다.

- 엑셀에서 그려진 적합선과 회귀식은 도대체 어떻게 추정된 것일까?
- 일단 회귀식이 추정되었다면 새로운 X_i 값이 주어질 때, (그에 대응하는) Y_i를 예측(predict)할 수 있다.
- 실제 자료 Y_i와 예측된(predicted) Y_i (혹은 $\widehat{Y}$) 간의 차이는 곧 오차(error)라고 볼 수 있다.

$$\widehat{e}_i = Y_i - \widehat{Y}_i = Y_i - (\widehat{\beta}_0 + \widehat{\beta}_1 X_i)$$

- 모집단에서는 오차 ϵ, 표본에서는 잔차(residuals) e라고 구분된다(하지만 종종 잔차도 그냥 오차라고 부른다).
- 회귀식에서 추정량(estimates)에 대해서는 이렇게 ˆ(hat)을 붙인다.

회귀분석

- 예상되는 오차 $\widehat{\epsilon}_i$를 줄인다는 것은 현실 자료와 이론적 예측 사이의 괴리를 줄인다는 의미와 일맥상통한다.
- 물론 (오차 하나만 줄이는 것이 아니라) 오차를 전체적으로 줄이는 것이 중요하다.
- 단, 오차의 합을 그냥 최소화하지 않고 오차 제곱의 합(sum of squared error; SSE)을 최소화한다(Why?).
- 오차 제곱의 합을 최소화하는 β_0와 β_1을 찾음으로써, 주어진 자료를 가장 잘 설명할 수 있는 모형을 만들 수 있게 된다.

$$\underset{b_0, b_1}{\operatorname{argmin}} \sum_{i}^{n} \epsilon_i^2$$

- 이것이 바로 단순최소자승(ordinary least squares; OLS)이다.

회귀분석

교육 목적상 단순회귀모형과 다중회귀모형을 구분한다.

- 단순회귀모형에서는 오로지 독립변수(X)와 종속변수(y), 딱 두 개의 변수만 고려하였다.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- 반면, (종속변수는 여전히 1개지만), 모델 안에 독립변수가 여러 개(k) 투입된 경우를 다중회귀모형(multiple regression model)이라고 부른다.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + ... + \beta_k X_{ki} + \epsilon_i$$

- 현실에서는 아무도 단순회귀모형을 사용하지 않는다. 그건 학습용/연습용이고 실무/연구 목적에서는 다중회귀모형을 사용한다.

회귀분석

단순회귀모형에서는 "독립변수 X의 값이 한 단위 변화하면 종속변수 Y가 회귀계수 b_1만큼 변화한다"고 해석했다.

- 가령 결석 시수(skipped)가 올해 학점(termgpa)에 영향을 미친다는 회귀모형을 세우고 "오차항을 최소화하는 b_0와 b_1"을 다음과 같이 추정하였다고 하자.

$$termgpa_i = 3.043 - 0.076 skipped_i$$

- "결석 시수가 한 단위 증가할 때, 올해 학점은 -0.076점만큼 감소한다."
- "결석 시수가 0일 때의 올해 학점은 3.043이다."
- t 검정을 통해 모집단에서 $H_0 : \beta_1 = 0$ 인지 여부를 유의성 검정(significance test) 할 수도 있었다.

$$t = \frac{\widehat{b}_1}{se_{\widehat{b}_1}}$$

회귀분석

반드시 회귀분석과 함께 산점도와 적합선을 그려 선형관계를 확인해야 한다.

- 회귀모형은 y와 X 사이의 선형관계를 β_1 라는 기울기와 β_0 라는 절편으로 나타낸다.
- 가장 중요한 독립변수와 종속변수의 관계를 묘사하기 위해 산점도와 적합선을 그리는 것은 좋은 분석전략이다.
- 산점도를 통해 비선형관계가 있거나 극단치가 존재하는지 여부를 세심히 살펴보아야 한다.

회귀분석

다중회귀분석은 (다른 변수들의 효과를 통제한 상태에서) 특정 변수의 순효과를 살펴보는데 유용하다.

- 여러 개의 독립변수를 모델에 투입했다면 여러 영향력은 각각에 해당되는 변수 안으로 나뉘어 흡수된다.
- 그러므로 다중회귀분석은 "다른 변수의 영향력으로부터 독립된" 특정 변수의 순효과 (net effect) 또는 부분효과(partial effect)을 살펴보는데 유리하다.
- 예컨대, 임금(ln_wage)을 종속변수로, 나이(age) 및 직무경험(ttl_exp)을 독립변수로 하는 선형모형을 세웠다고 하자.

$$ln_wage = b_0 + b_1 age + b_2 ttl_exp + e$$

- 회귀분석을 통해 "나이(age)의 효과를 통제했을 때(즉 같은 나이일 때)" 직무경력 (ttl_exp)이 한 단위 변화하면 임금(ln_wage)이 얼마만큼 변화하는지 파악할 수 있다.

회귀분석

더미변수를 활용하여 질적 차이를 회귀분석에서 부각시킬 수 있다.

- 회귀분석에서는 숫자형 변수만 사용할 수 있다고 언급했다. 그렇지만 범주형 변수인 인종(1=백인; 2=흑인; ...)이나 종교(0=없음; 1=기독교; 2=불교; ...)를 회귀분석에서 "독립변수"로 사용할 수는 없을까?
- 더미변수를 활용한다면 범주형 변수를 회귀분석에서도 사용할 수 있다!
- 더미 변수란 처방, 조건, 또는 상황 등이 존재하면(present) 1로, 그것이 부재하면(absent) 0으로 더미 코딩(dummy coding)된 변수이다.
- 예를 들어, "처방 상태"에 관한 더미변수(treatment dummy)라면 받았다(1) 또는 안받았다(0) 중 하나의 값을 갖는다. "성별이 여성이다"에 관한 더미변수라면 그렇다(1) 또는 아니다(0) 중 하나가 된다.
- 더미변수는 이른바 명목변수(nominal variable)의 가장 단순한 형태(!)이다.

회귀분석

회귀분석 안에서 더미변수의 작동 원리와 해석은 매우 간단하다.

- 숫자형 독립변수인 X를 아래와 같은 단순회귀모형에 집어넣었다면, "X가 한 단위 증가할 때 y가 $\widehat{\beta}_1$ 만큼 변화한다" 그리고 "X가 0일 때, y는 $\widehat{\beta}_0$와 같다" 라고 해석할 수 있다.

$$Y_i = \beta_0 + \beta_1 X_i$$

- 위 모형에서 만약 X가 숫자형 변수가 아니라 더미변수라도 해석은 마찬가지이다. 제일 보편적인 더미변수인 성별을 예로 들자. 이때 남자는 0, 여자는 1로 더미 코딩되었다고 하자.

$$\widehat{Y}_{남} = \widehat{b}_0 \qquad (\text{if } X_i = 0)$$
$$\widehat{Y}_{여} = \widehat{b}_0 + \widehat{b}_1 \qquad (\text{if } X_i = 1)$$

- 그러므로 남녀 간 $\widehat{Y}$의 격차는 $\widehat{Y}_{여} - \widehat{Y}_{남} = \widehat{b}_1$이다. 그 효과는 단지 더미변수의 회귀계수 $(\widehat{b}_1)$에 나타나 있다!

회귀분석

- 만일 범주형 변수인 종교가 “기독교=1, 천주교=2, 불교=3, 원불교=4, 기타=5, 종교없음=6”으로 주어졌다고 하자.
- 그런데 위의 범주형 변수에서 6개의 더미변수를 만들었더라도 이 모든 변수를 독립변수로 집어넣을 수는 없고 반드시 하나를 빼고 집어넣어야만 한다. 아까 예제 2에서 도시 더미변수 외에 비도시 더미변수를 따로 넣지 않았던 이유도 여기에 있다.
- 그렇게 빠진 변수를 기준범주(reference category)라고 부른다. 모든 더미변수의 해석은 기준범주에 비교하여 이루어진다. 그러므로 아까 도시 더미변수를 해석할 때도 비도시에 비교하여 해석이 이루어졌다.
- 하나를 빼야 하는 이유는 (1) 나머지 5개의 더미변수로부터 마지막 하나의 더미변수 내용을 완벽하게 추측할 수 있고 (2) 회귀분석의 가정상 똑같은 독립변수를 여러개 집어넣어서는 안되기 때문이다.

회귀분석

예제 4. college.csv를 사용하여 등록금이 졸업생의 평균수입에 미치는 영향을 살펴보고자 한다. 이때 졸업율(grad), 학자금 상환비율(debt), 도시에 캠퍼스가 있는지 여부(city)의 영향력을 함께 통제하여 졸업생의 평균수입(earnings)을 예측하는 회귀모형을 만들고 추정하시오. 이 분석의 결과에 관해서도 자세하게 논의하시오.

회귀분석

- 등록금와 평균수입의 관계는 다음과 같이 산점도와 적합선으로 표현될 수 있다.

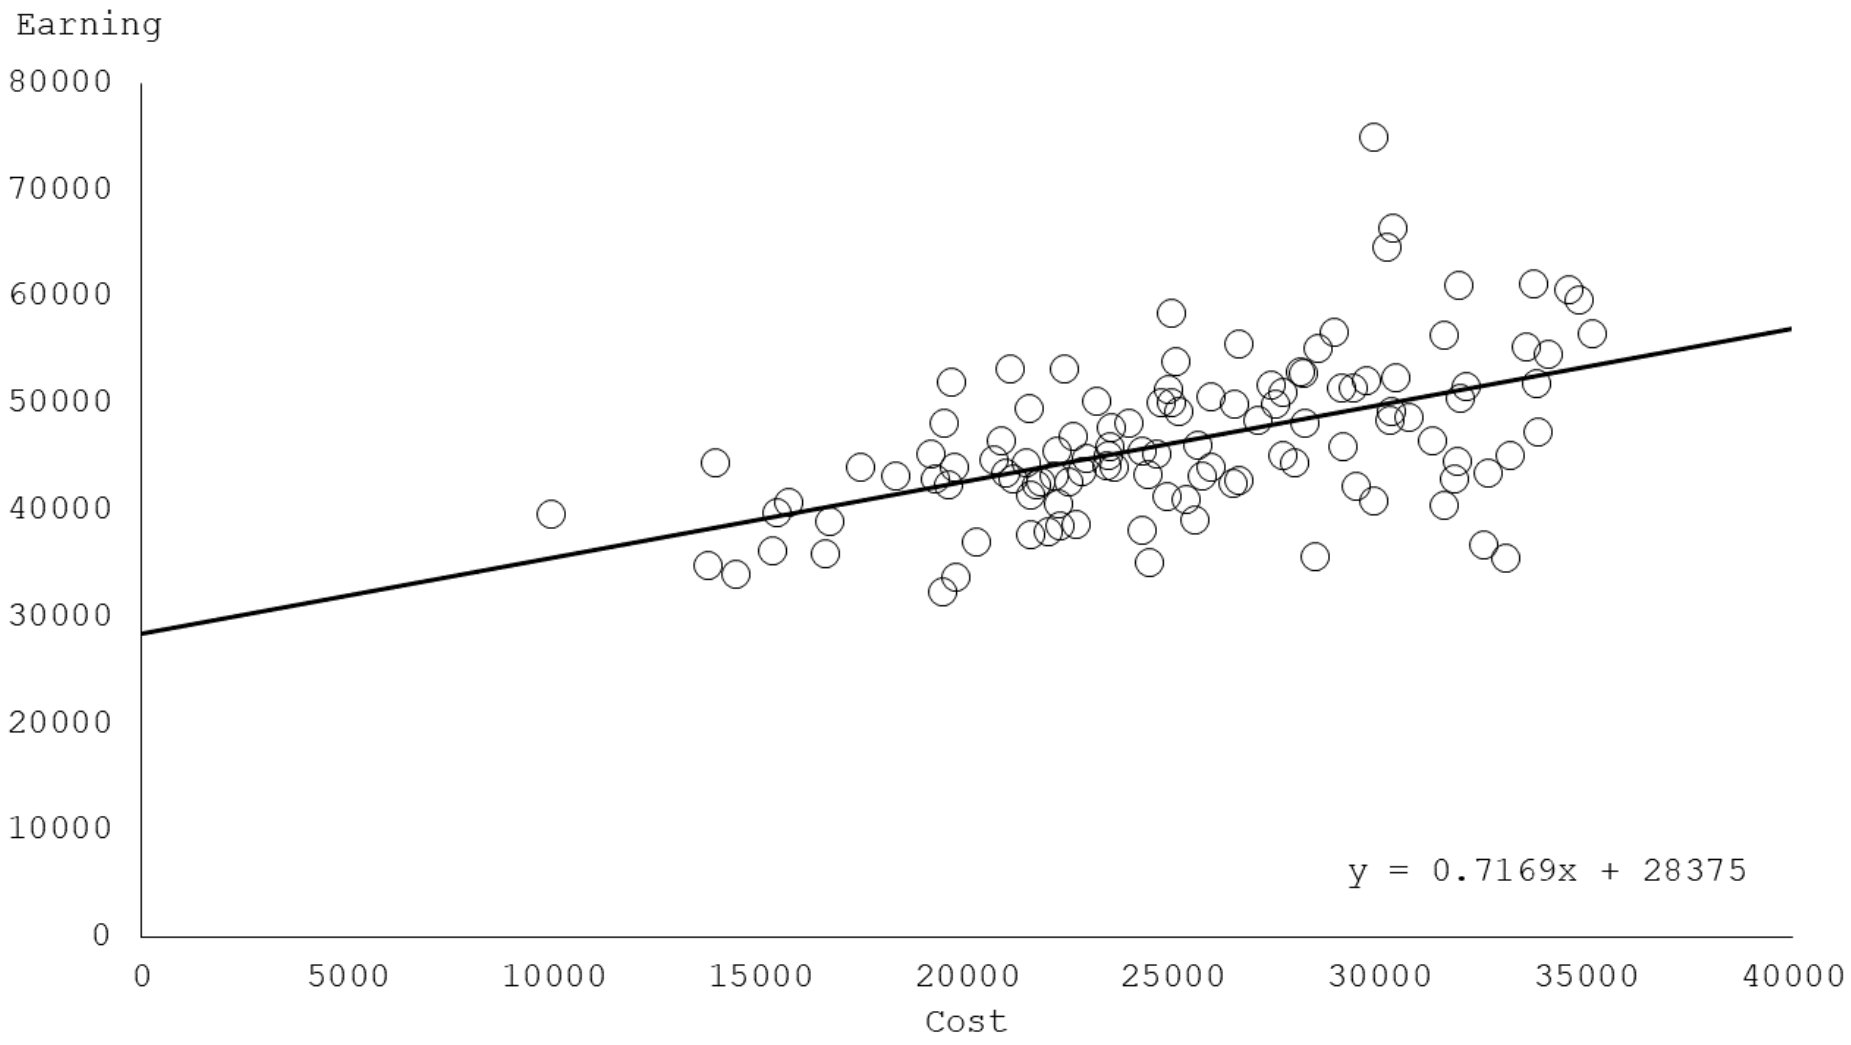

회귀분석

- 산점도에서 추정된 식은 오로지 단순회귀분석에 불과하므로 다른 변수들의 영향력을 제대로 반영하지 못하고 있다.
- 반면 단순최소자승(OLS)에 따라 추정된 다중회귀식은 다음과 같이 얻어졌다.

$$earnings = 10004.97 + 141.49 \cdot debt + 0.43 \cdot cost + 178.10 \cdot grad + 2526.79 \cdot city$$

- "다른 변수들의 영향력을 통제하였을 때, 등록금이 1000달러 증가하면 평균수입은 430달러만큼 증가한다."
- 더미변수인 City의 회귀계수는 2526.789 이므로 "도시 대학을 졸업한 사람은 비도시 대학을 졸업한 사람보다 약 2,527달러 평균수입이 높다"고 해석할 수 있다.
- 보통 통계적으로 유의하지 않으면 (찻잔 속의 태풍이므로) 해석을 아예 하지 않는 경우가 많다.

회귀분석

- Cost, Grad, Debt의 중위값(median)은 각각 24957.5, 67, 90이다. 이를 아래 회귀식에 대입하면 아래와 같다.

$$
\begin{aligned}
earnings_i &= 10004.966 + 0.435Cost + 178.099Grad + 141.478Debt + 2526.789City \\
&= 10004.966 + 0.435 \cdot 24957.5 + 178.099 \cdot 67 + 141.478 \cdot 90 + 2526.789City \\
&= 45527.132 + 2526.789City
\end{aligned}
$$

- 다른 모든 변수들이 중위값에 고정되었을 때, 비도시 대학 졸업자(City=0)의 예상되는 평균수입($\widehat{earnings}$)은 약 45,527 달러이다.
- 다른 모든 변수들이 중위값에 고정되었을 때, 도시 대학 졸업자(City=1)의 예상되는 평균수입($\widehat{earnings}$)은 약 48,054 달러이다.

회귀모형의 적합도

회귀모형의 적합도

제안된 회귀모형이 자료에 얼마나 적합한지 살펴보아야 한다.

- 우리가 모형을 세워 그것을 현실 데이터에 맞추어(fit) 본 이상, 이것이 얼마나 잘 맞는가를 말할 수 있어야.
- 우리는 여러가지 적합도(goodness-of-fit) 지표 가운데 결정계수(coefficient of determination)와 분산분석만 공부하였다.

회귀모형의 적합도

먼저 결정계수를 살펴보자.

- 우리에게 데이터가 주어지고 여기에 전체 변량(total variation)이 있다면, 이것은 모형에 의해 설명된 변량(explained variation)과 (그렇지 못하고) 남은 변량(residual variation)의 합이라고 할 수 있다.

$$\sigma^2_{total} = \sigma^2_{explained} + \sigma^2_{residual}$$

- 아래 "설명된 변량의 비율(ratio)"은 모형의 높은 설명력을 의미한다고 볼 수 있다.

$$R^2 = \frac{\sigma^2_{explained}}{\sigma^2_{total}} = 1 - \frac{\sigma^2_{residual}}{\sigma^2_{total}}$$

- 이것이 바로 결정계수(R^2)의 직관적 의미이다. 설명된 변량의 "비율"이므로 0과 1 사이에 놓인다. 1에 가까울수록 모델은 높은 적합도를 보인다고 할 수 있다.
- 이제 남은 문제는 세 변량들이 어떤 식으로 정의되는가를 파악하는 것이다.

회귀모형의 적합도

독립변수 X가 없을 때 종속변수 Y를 가장 잘 예측하는 요소는 무엇일까?

- 이 질문은 생각보다 매우 중요하다! 그것은 바로 종속변수의 평균 $\bar{Y}$이다(Why?). 우리는 사실 학기 초에 중심성향(central tendency)에 관해 공부하면서 이것을 은근슬쩍 배웠다.
- 이 원리는 우리에게 중요한 원칙 하나를 제공한다: 어떤 모델을 세우던지 최소한 종속변수의 평균 $\bar{Y}$보다는 나은 설명력을 보여야 한다.
- 종속변수의 평균 $\bar{Y}$은 일종의 기준점이자 최소한의 바닥이다. 이것보다도 못한 모델은 아무런 가치도 없다.
- 한편 종속변수의 실제 값 Y_i은 일종의 이상점이자 최고의 천장이다. 이것은 모델이 추구할 수 있는 최고의 이상이다.
- (직관적으로 설명한다면) 당연히 모델의 예측값 $\widehat{Y}_i$은 Y_i와 $\bar{Y}$ 사이 어딘가 놓이리라 생각할 수 있다(실제로는 꼭 그렇지 않을수도 있지만 너무 신경쓰지 말자).

회귀모형의 적합도

- 그림을 통해서 우리는 총변량이 “잔여 변량”과 “설명된 변량”의 합임을 직관적으로 이해할 수 있다.

$$(Y_i - \bar{Y}) = (Y_i - \widehat{Y}_i) + (\widehat{Y}_i - \bar{Y})$$

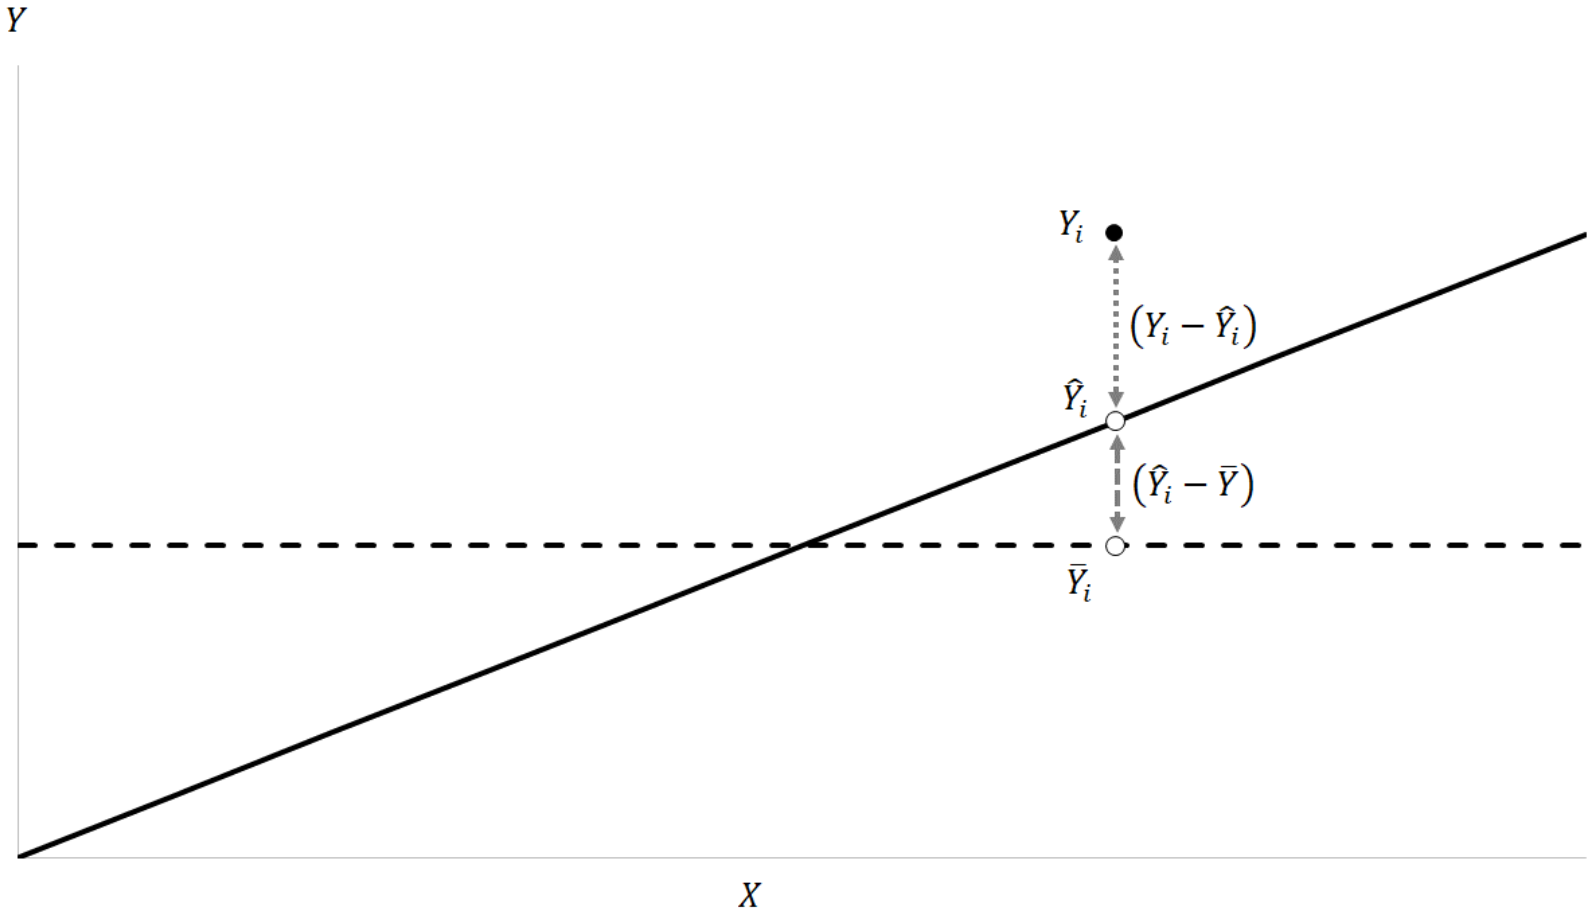

회귀모형의 적합도

- 우리는 이제 제곱합(Sum of Squares; SS) 개념을 가지고 다음의 공식에 도달할 수 있다.

$$\sum(Y_i - \bar{Y})^2 = \sum(Y_i - \widehat{Y}_i)^2 + \sum(\widehat{Y}_i - \bar{Y})^2$$
$$SS_{total} = SS_{residual} + SS_{explained}$$

- 이제 결정계수 R^2를 측정할 수 있다.

$$R^2 = \frac{SS_{explained}}{SS_{total}} = \frac{\sum(\widehat{Y}_i - \bar{Y})^2}{\sum(Y - \bar{Y})^2} = 1 - \frac{SS_{residual}}{SS_{total}} = 1 - \frac{\sum(Y_i - \widehat{Y}_i)^2}{\sum(Y_i - \bar{Y})^2}$$

- 아까 그림을 통해 되새겨보면, Y_i에 더 가까운 위치에 $\widehat{Y}_i$가 놓일수록 R^2 역시 높으리라고 추측할 수 있다.

회귀모형의 적합도

분산분석(ANOVA) 결과표에서 도출된 F 값 역시 모형 전체의 적합도를 보여준다.

- 아래와 같이 선형모형을 설정하였을 때 최악의 추정 결과는 무엇일까?

$$Y_i = \beta_0 + \beta_1 X_i + \cdots + \beta_{k-1} X_{k-1} + \beta_k X_k + \epsilon_i$$

- 그건 (상수 빼고) 모든 회귀계수가 0이 되는 상황이다. 보다 구체적으로 말해서 "모집단에서 (상수 빼고) 모든 β가 0인 상황"이다.
- 제대로 된 모형이라면 최소한 이런 경우는 부정할 수 있어야 한다. 만일 이런 상황을 부정할 수 없다면 "이 모델은 완전히 쓸모없다" 라는 말을 부정할 수 없는 것이나 마찬가지이기 때문이다.

회귀모형의 적합도

- 그러므로 다중회귀분석 맥락에서 수행되는 다음과 같은 가설구조를 검증해 볼 수 있다.

$$H_0 : \beta_1 = \beta_2 = ... = \beta_k = 0$$
$$H_a : (\beta_1 \neq 0) \text{ or } (\beta_2 \neq 0) \text{ or } ... \text{ or } (\beta_k \neq 0)$$

- 이 가설구조를 테스트할 수 있는 검정 방법은 일원분산분석이다.
- 일원분산분석의 검정통계량 F 값은 다음과 같다. 단 k는 독립변수의 수를 의미한다.

$$F_{(k,n-k-1)} = \frac{MS_{between}}{MS_{within}} = \frac{SS_{between}/k}{SS_{within}/(n-k-1)}$$

- F 값이 클수록 유의확률(p-value)이 작아지므로(Why?) 위 귀무가설을 기각할 수 있다.

회귀모형의 적합도

다시 college 데이터의 회귀분석 결과를 되돌아보자.

- 이제 분산 분석으로 제시된 표가 어떤 의미인지 이해할 수 있다. 이 결과표를 찬찬히 뜯어보면서 재현해보자.
- 유의확률이 0.05보다 작다는 사실은 95% 신뢰수준에서 다음의 귀무가설을 기각할 수 있다는 의미이다.

$$H_0 : \beta_1 = \cdots = \beta_k = 0$$

- 우리는 "모든 회귀계수가 0이다"라는 귀무가설을 기각하고 "최소한 하나의 회귀계수는 0이 아니다"라는 대립가설을 채택할 수 있었다. 다행이다~

회귀모형의 적합도

- "네 변수를 사용한 선형모형은 데이터의 전체 변량 중 42.9%를 설명한다."
- 0.429라는 결정계수는 너무 낮을까? 그렇지만도 않다. 겨우 몇 개의 변수만으로 이 정도 설명했다는 것은 나름 탁월하다. 많은 사회과학 연구를 돌이켜볼 때 이 정도면 제법 괜찮다.
- 바로 아래 조정된 결정계수(adjusted R^2)는 무엇인가? 기본적으로 결정계수는 보다 많은 독립변수를 집어넣을 때 무제한적으로 팽창하는 성향이 있다. 그런데 이것은 오캄의 면도날 원칙(Occam's Razor)에 반하는 것이므로, 독립변수를 추가적으로 집어넣을 때마다 적절한 패널티를 가할 필요가 있다. 조정된 결정계수는 바로 이렇게 패널티가 가해진 결정계수이다.